

Pravděpodobnost & statistika 1

definice

Prostor jevů

$\mathcal{F} \subseteq P(\Omega)$ je prostor jevů (též σ-algebra), pokud:

1) $\emptyset \in \mathcal{F}$ a $\Omega \in \mathcal{F}$

2) $A \in \mathcal{F} \Rightarrow \Omega / A \in \mathcal{F} = A^c$ nazýváme A -complement

3) $A_1, A_2, \dots \in \mathcal{F} \Rightarrow \bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$

Axiomy pravděpodobnosti

$P: \mathcal{F} \rightarrow [0,1]$ se nazývá pravděpodobnost, pokud:

1) $P(\emptyset) = 0$

2) $P(\Omega) = 1$

3) $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ pro libovolnou posloupnost počtu disjunktivních jevů

Pravděpodobnostní prostor

je trojice (Ω, \mathcal{F}, P) taková, že:

- 1) $\Omega \neq \emptyset$ je libovolná množina
- 2) $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ je prostor jeho
- 3) P je pravděpodobnost

Podmíněná pravděpodobnost

Pokud $A, B \in \mathcal{F}$ a $P(B) > 0$, definujeme podmíněnou pravděpodobnost A při B jako:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Platí, že pro $\underbrace{Q(A) := P(A|B)}$ je (Ω, \mathcal{F}, Q) pravděpodobnostní prostor.
"podmíněnou PSTM. fci"

Rozklad Ω

"rozbor všech možností"

Spočet my systém množin $B_1, B_2, \dots \in \mathcal{F}$ je rozklad Ω , pokud:

1) $B_i \cap B_j = \emptyset$ pro $i \neq j$

2) $\bigcup B_i = \Omega$

Nezávislost jevů

Jevy $A, B \in \mathcal{F}$ jsou nezávislé, pokud:

$$P(A \cap B) = P(A)P(B)$$

Pak, pokud je $P(B) > 0$, platí:

$$P(A|B) = P(A)$$

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B)}{P(B)} = P(A) \quad \text{④}$$

Nezávislost více jevů

Jevy $\{A_i : i \in I\}$ jsou víceméně nezávislé, pokud pro každou konečnou množinu $J \subseteq I$ platí:

$$P(\bigcap_{i \in J} A_i) = \prod_{i \in J} P(A_i)$$

* odkaz na def. nez. jevu
"prémik \wedge se spočítá snížením \wedge "

Pokud podmínka platí jen pro dvojuprukou množinu J , nazýváme jevy $\{A_i\}$ **po dvou** nezávislé.

Náhodná veličina

Mějme pravděpodobnostní prostor (Ω, \mathcal{F}, P) . Funkci $X: \Omega \rightarrow \mathbb{R}$ nazoveme diskrétní náhodná veličina, pokud $\text{Im}(X) = \text{obor hodnot } X$ je spočetná množina a pokud pro $x \in \mathbb{R}$ platí:

$$\{\omega \in \Omega : X(\omega) = x\} \in \mathcal{F}$$

aby ta veličina byla diskrétní

Ω je vlastně $\{x^{-1}(x)\}, P(x^{-1}(x))$ ale používáme zapisovou jako $P(X=x)$

Pravděpodobnostní funkce

7. fce. diskrétní náhodné veličiny X je funkce $P_X: \mathbb{R} \rightarrow [0,1]$ taková, že:

$$P_X(x) = P(X=x) = v \text{ podstatě hustodlní fce pro d.m.v.}$$

$$\sum_{x \in \text{Im}(X)} P_X(x) = 1$$

$$\rightarrow A \subseteq \mathbb{R}, f: A \rightarrow [0,1], \sum_{a \in \text{Im}(A)} f(a) = 1$$

2) poští prostor dokážeme vytvořit z lib. podmnožiny \mathbb{R} a vhodné fce

Sřední hodnota

"popisuje očekávanou hodnotu m.v."

Pokud je X diskrétní náhodná veličina, tak je její sřední hodnota označována $E(X)$ a definována:

$$E(X) := \sum_{x \in \text{Im}(X)} x \cdot P(X=x) = \sum_{\omega \in \Omega} X(\omega) \cdot P(\{\omega\})$$

pokud má součet smysl.

* $\text{Im}(X)$ musí být spočetná, jinak hrozí (" $+\infty - \infty$ ")

Podmíněná střední hodnota

Pokud je X diskrétní měřidelná veličina a $P(\mathcal{D}) > 0$, tak podmíněná střední hodnota X za předpokladu \mathcal{D} je:

$$\mathbb{E}(X|\mathcal{D}) = \sum_{x \in \text{elm}(X)} x \cdot P(X=x|\mathcal{D})$$

pokud má součet smysl

Rozptyl

"popisuje odchylku hodnoty m.v. od její střední hodnoty"

Variance m.v. X nazveme číslo:

"aka střední kvadratická odchylka"

$$\text{var}(X) = \mathbb{E}((X - \mathbb{E}X)^2)$$

* musí platit: $\text{var}(X) \geq 0$

* $\text{var}(X) = 0 \iff P(X \neq \mathbb{E}(X)) = 0$


Bernoulliho (alt.) rozdělení "X = počet orle při jednom hodu nespravedlivou minci"

$$X \sim \text{Bern}(p)$$

$$\mathbb{E}(X) = p$$

$$\text{var}(X) = p(1-p)$$

$$\begin{aligned} P_X(1) &= p \\ P_X(0) &= 1-p \\ P_X(k) &= 0 \quad \forall k \neq 0, 1 \end{aligned}$$



pro libovolný jev $A \in \mathcal{F}$ definujeme indikátorovou m.v. I_A :

$$I_A(\omega) = \begin{cases} 1 & \text{pokud } \omega \in A \\ 0 & \text{jimak} \end{cases}$$

$$I_A \sim \text{Bern}(P(A))$$

Binomické rozdělení "X = počet orlů při n hodcích nezávislých minci"

$$X \sim \text{Bin}(n, p)$$

n : počet hodí, p : pravd. že padne orel
 $\rightarrow p \in [0, 1]$

$$P_X(k) = \binom{n}{k} p^k \cdot (1-p)^{n-k}$$

pro $k \in \{0, 1, \dots, n\}$

⊗ pravd. fce:
z n hodů k orlů



způsobů jak
uspět
 $* P(\text{že } k\text{-krátk uspěj})$

$$p = \frac{1}{2}$$

$$p = \frac{1}{10}$$

$$\mathbb{E}(X) = np$$

$$\text{var}(X) = np(1-p)$$



Poissonovo rozdělení

" $X = \text{počet emailů, které dostaneme za časový úsek}$ "

$$X \sim \text{Pois}(\lambda) \quad \lambda \in \mathbb{R}, \lambda > 0$$

$$P_X(k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

$$\mathbb{E}(X) = \lambda$$

$$\text{var}(X) = \lambda$$

⊗ Pois(λ) je limitou:

$$\text{Bin}\left(m, \frac{\lambda}{m}\right)$$

máme-li $X_m \sim \text{Bin}\left(m, \frac{\lambda}{m}\right)$ pak:

$$P(X_m=k) = \binom{m}{k} \left(\frac{\lambda}{m}\right)^k \left(1 - \frac{\lambda}{m}\right)^{m-k}$$

$\underbrace{\frac{\lambda^k}{k!}}_{\text{konst}}$ $\underbrace{\left(1 - \frac{\lambda}{m}\right)^m}_{\substack{\rightarrow \\ \text{konv}}} \cdot \underbrace{\frac{m(m-1)\dots(m-k+1)}{m^k}}_{\substack{\rightarrow 1 \\ \text{konv.}}} \underbrace{\left(1 - \frac{\lambda}{m}\right)^{-k}}_{\substack{\rightarrow 1 \\ \text{konv.}}}$


Geometrické rozdělení "X = Orel poprvé padl k-tým hodem"

$$X \sim \text{Geom}(p) \quad p \in [0,1]$$

$$P_X(k) = (1-p)^{k-1} \cdot p \quad k = 1, 2, 3, \dots \quad * \text{ pro } p = \frac{1}{2} \quad \underbrace{P_X(k)}_{\text{je}} = p^k$$

$$\mathbb{E}(X) = \frac{1}{p}$$

$$\text{var}(X) = \frac{1}{p} \left(\frac{1-p}{p} \right)$$




Sdružené rozdělení

Pro diskrétní m.v. X, Y na pravděpodobnostním prostoru (Ω, \mathcal{F}, P) definujeme jejich sdruženou pravděpodobnostní funkci $P_{X,Y} : \mathbb{R}^2 \rightarrow [0,1]$ předpisem:

$$P_{X,Y}(x,y) = P(\{\omega \in \Omega : X(\omega) = x \text{ a } Y(\omega) = y\}) = P(X=x, Y=y)$$

* definice funguje i pro více než dve měřitelné veličiny: $P_{X_1, \dots, X_n}(x_1, \dots, x_n)$



* sdružené rozdělení $P_{X,Y}$

* marginální rozdělení P_X

* marginální rozdělení P_Y



1) z $P_{X,Y}$ lze získat P_X a P_Y

2) z P_X, P_Y nelze získat $P_{X,Y}$

Nezávislost měr. veličin

Diskrétní m.v. X, Y jsou **nezávislé**, pokud pro $\forall x, y \in \mathbb{P}$ jsou jevy $\{X=x\}$ a $\{Y=y\}$ nezávislé, což platí právě když:

$$P(X=x, Y=y) = P(X=x) \cdot P(Y=y)$$

*) v případě nezávislých X, Y lze def. sloužené rozd. $P_{X,Y} \leftarrow P_X, P_Y$ právě jako jejich součin

Směrodatná odchylka

Pro m.v. X definujeme její **směrodatnou odchylku** jako:

$$\sigma_X = \sqrt{\text{var}(X)}$$

Obecná náhodná veličina

Náhodná veličina na (Ω, \mathcal{F}, P) je zobrazení $X: \Omega \rightarrow \mathbb{R}$, které pro $\forall x \in \mathbb{R}$ splní:

$$\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F}$$

*) diskrétní m.v. je obecná m.v.

Distribuční funkce "kumulativní" protože se kumuluje (masíta) na 1

Dist. fce. náhodné veličiny X je funkce:

$$F_X(x) := P(X \leq x) = P(\{\omega \in \Omega : X(\omega) \leq x\})$$

• F_X je neklesající fce

• $\lim_{x \rightarrow -\infty} F_X(x) = 0$

• $\lim_{x \rightarrow +\infty} F_X(x) = 1$

• F_X je zprava spojita

protože jdeme zprava a dojdeme až do bodu, když zleva, v bodě skok

$$P(X \leq x + \epsilon) \rightarrow P(X \leq x) \text{ pro } \epsilon \rightarrow 0^+$$


$x \rightarrow +\infty$ do Ω pribývají + body $\rightarrow P(\Omega) = 1$

$x \rightarrow -\infty \in \Omega$ mizí body $\rightarrow P(\emptyset) = 0$


příklad:

$$X \sim \text{uniform.}(\{0, 1, 2, 3\})$$

* pravd. fce



$$F_X$$



* distrib. fce

Spojita náležitá veličina

m.v. X je nazývána **spojitá**, pokud existuje mezikontinuální reálná funkce f_X tak, že:

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(t) dt$$

funkce f_X se nazývá **HUSTOTA**



P_X pravděpodobnostní fce

F_X distribuční fce


f_X hustodlní fce

Střední hodnota spojité m.v.

Nechť spojita m.v. X má hustotu f_X . Pak je její **střední hodnota** je označována $E(X)$ a definována:

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f_X(x) dx$$

ma-li integrál smysl tedy nemí " +∞ - ∞ "



$$E(X) = \sum_m \int_m^{m+1} x \cdot f_X(x) dx \rightarrow \text{platí rovnost protože integrujeme přes celou } \mathbb{R}, \text{ ale po částech}$$

$$= \sum_m m \cdot \int_m^{m+1} f_X(x) dx = \sum_m m \cdot P(m \leq X \leq m+1) \rightarrow \text{m.v. zahrávající dobu na cele číslo}$$

\Rightarrow pro knopy v $\sum \rightarrow 0,00 \dots 1 \rightarrow$ se blížíme k $\sum_k k \cdot P(X=k)$

Rozptyl spojité m.v.

Výzva:

"1. moment" ... $E(X) = \int_{-\infty}^{+\infty} x \cdot f_x(x) dx$

"2. moment" ... $E(X^2) = \int_{-\infty}^{+\infty} x^2 \cdot f_x(x) dx$... spojitý LOTUS pro $g(x) = x^2$

Proto označme-li $\mu = E(X)$, tak:

$$\text{var}(X) = \int_{-\infty}^{+\infty} (x - \mu)^2 f_x(x) dx = E(X^2) - E(X)^2$$

↓
 def
 $E(X - \mu)^2$
 " "
 $E(x - E(x))^2$

$$E(cx) = c E(X)$$

$$E(x+y) = E(x) + E(y)$$

(*) rozptyl počítame "jako u diskretních m.v.", nejpravidelněji bývá

"k-tý moment" ... $E(X^k) = \int_{-\infty}^{+\infty} x^k \cdot f_x(x) dx$

Uniformní rozdělení

$$X \sim U(a, b)$$

$$F_x = \begin{cases} 0 & \text{pro } x \leq a \\ \frac{x-a}{b-a} & \text{pro } a < x < b \\ 1 & \text{pro } x \geq b \end{cases}$$

$$f_x = \frac{1}{b-a} \quad \text{pro } x \in [a, b]$$

$$\bar{E}(x) = \frac{a+b}{2}$$

$$= \int_a^b x \cdot \frac{1}{b-a} = \left[\frac{x^2}{2} \right]_a^b \cdot \frac{1}{b-a} = \left(\frac{b^2}{2} - \frac{a^2}{2} \right) \cdot \frac{1}{b-a} = \frac{\cancel{b^2} - \cancel{a^2}}{2(b-a)} = \frac{a+b}{2}$$

$$\text{var}(x) = \frac{(b-a)^2}{12}$$

$$\sigma_x = \frac{b-a}{2} \cdot \frac{1}{\sqrt{3}} = \sqrt{\text{var}(x)}$$

⊗ $\int_{-\infty}^{+\infty} (x - \mu)^2 \cdot f_x(x) \cdot dx \quad \dots \quad \bar{E}(x) = \mu$

$$= \int_a^b \left(x - \frac{b-a}{2} \right)^2 \cdot \frac{1}{b-a} \cdot dx = \int_{-\frac{b-a}{2}}^{\frac{b-a}{2}} y^2 \cdot \frac{1}{b-a} dy = \left[\frac{y^3}{3} \right]_{-\frac{b-a}{2}}^{\frac{b-a}{2}} \cdot \frac{1}{b-a} = \left(\frac{(b-a)^3}{3 \cdot 8} + \frac{(b-a)^3}{3 \cdot 8} \right) \cdot \frac{1}{b-a} = \frac{2(b-a)^3}{24} \cdot \frac{1}{b-a} = \frac{(b-a)^2}{12}$$


čím větší vel. interval
tím větší rozptyl,
roste kvadraticky




Exponenciální rozdělení

$$X \sim \text{Exp}(\lambda) \quad \text{pro } \lambda > 0$$

$$F_X(x) = \begin{cases} 0 & \text{pro } x \leq 0 \\ 1 - e^{-\lambda x} & \text{pro } x \geq 0 \end{cases}$$



$$f_X(x) = \begin{cases} 0 & \text{pro } x \leq 0 \\ \lambda e^{-\lambda x} & \text{pro } x \geq 0 \end{cases}$$



jak se počítá: $\int f_X = \int_0^\infty \lambda e^{-\lambda x} = \left[-e^{-\lambda x} \right]_0^\infty = 0 - (-1) = 1$

$$\mathbb{E}(x) = \frac{1}{\lambda} \quad \text{per partes} = \int_0^\infty x \cdot \lambda e^{-\lambda x} dx = \underbrace{\left[x \cdot (-e^{-\lambda x}) \right]_0^\infty}_{\substack{\text{Avr.} \\ \text{integ.}}} - \underbrace{\int_0^\infty 1 \cdot (\lambda e^{-\lambda x}) dx}_{\substack{\text{+}}} = \int_0^\infty \lambda e^{-\lambda x} dx = \frac{1}{\lambda}$$

$$\mathbb{E}(x^2) = \int_0^\infty x^2 \cdot \lambda e^{-\lambda x} dx = \left[x^2 \cdot (-e^{-\lambda x}) \right]_0^\infty - \int_0^\infty 2x \cdot (-e^{-\lambda x}) dx = \int_0^\infty 2x \cdot e^{-\lambda x} dx = \frac{2}{\lambda} \cdot \int_0^\infty x \cdot \lambda e^{-\lambda x} dx = \frac{2}{\lambda^2}$$


$$\text{var}(x) = \frac{1}{\lambda^2} = \mathbb{E}(x^2) - \mathbb{E}(x)^2 = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda} \right)^2 = \frac{1}{\lambda^2}$$

$$\sigma_x = \frac{1}{\sqrt{\lambda}}$$

⊗ suda' fce

Normální rozdělení

$$\begin{array}{c} \mathbb{E}(z) \\ \parallel \\ \text{var}(z) \\ \parallel \\ z \sim \text{Norm}(0,1) \end{array}$$



$F_z(z) = \Phi(z)$ = primitivní fce k $\varphi(z)$, nejde výjedně pomocí elem. fcí

$$f_z(z) = \varphi(z) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{z^2}{2}}$$

proč je $\varphi(z)$ aust. fce?

$$\int_{-\infty}^{+\infty} e^{-\frac{z^2}{2}} = C = \sqrt{2\pi} \Rightarrow \int_{-\infty}^{+\infty} \varphi(z) = 1$$


$$\mathbb{E}(z) = 0 = \int_{-\infty}^{+\infty} z \cdot \underbrace{\varphi(z)}_{\text{suda' erola'}} = 0$$

$$\text{var}(z) = 1 = \mathbb{E}(z^2) - \underbrace{\mathbb{E}(z)^2}_0 = \mathbb{E}(z^2) = \int_{-\infty}^{+\infty} z^2 \cdot \varphi(z) = \int_{-\infty}^{+\infty} z \cdot \frac{1}{\sqrt{2\pi}} \cdot z \cdot e^{-\frac{z^2}{2}} = \underbrace{\left[\frac{z^2}{\sqrt{2\pi}} \cdot -e^{-\frac{z^2}{2}} \right]_{-\infty}^{+\infty}}_{=0} + \int_{-\infty}^{+\infty} 1 \cdot \varphi(z) = 1$$

???

Cauchyho rozdělení

$$f_x(x) = \frac{1}{\pi(1+x^2)}$$



$E(X)$ neexistuje nelze zintegrovat " $\infty - \infty$ "

Gamma rozdělení, Beta rozdělení, χ^2 rozdělení s n° volnosti, Studentovo t-rozdělení

* budu dělat až ve statistice

Sdružená distribuční funkce

- Pro m.v. X, Y na prob. prostoru (Ω, \mathcal{F}, P) definujeme jejich sdruženou distribuční funkci $F_{X,Y} : \mathbb{R}^2 \rightarrow [0, 1]$ s předpisem:

$$F_{X,Y}(x, y) = P(\{\omega \in \Omega : X(\omega) \leq x \text{ a } Y(\omega) \leq y\})$$

píšeme $F_{X,Y} = P(X \leq x \text{ a } Y \leq y)$

- Dá se definovat: pro více než dve m.v.

$$F_{X_1, \dots, X_m}(x_1, \dots, x_m) = P(X_1 \leq x_1, \dots, X_m \leq x_m)$$

Sdružená hustota

- s dřuženou distribuční funkcí můžeme často psát jako integrál

přes nezápornou fci $f_{x,y}$:

$$F_{x,y}(x,y) = \int_{-\infty}^x \int_{-\infty}^y f_{x,y}(s,t) \cdot dt \cdot ds$$

$s = -\infty, \dots, x$ $t = -\infty, \dots, y$

(*) tedy vyjádřujeme distri. fci jako dvojitý integral přes hustotn. fci

- Potom můžeme r.v. X, Y sdruženě spojité. Funkce $f_{x,y}$ je jejich sdružená hust. fce.
- $f_{x,y} > 1$ je významné

**


Fubiniho věta \Rightarrow mohu (jsou-li splněny podm.) procházet integrály

$$F_{x,y}(x,y) = \int_{t=-\infty}^y \int_{s=-\infty}^x f_{x,y}(s,t) \cdot ds \cdot dt$$

Nezávislost spojitéch m.v.

Libovolné m.v. nazveme nezávislé, pokud jenž $\{X \leq x\} \cap \{Y \leq y\}$ jsou nezávislé pro libovolná $x, y \in \mathbb{R}$. Ekvivalentně:

- $P(X \leq x, Y \leq y) = P(X \leq x) \cdot P(Y \leq y)$
 - $F_{X,Y}(x, y) = F_X(x) \cdot F_Y(y)$
- dva způsoby
jich zapsat totéž



Podmínkování

X je m.v. na (Ω, \mathcal{F}, P) a $B \in \mathcal{F}$

$$F_{X|B}(x) := P(X \leq x | B) = \frac{P(X \leq x \text{ a } B)}{P(B)} = \int_{-\infty}^x f_{X|B}(s) ds$$

Plati vždy, že distrib. funkce je primitivní funkci k hustotní fcn. Pravdou

Podmíněná hustota

chceme pro $D = \{y=y\}$

umět: $f_{X|D}$ ale $P(D) = 0$

proto musíme jítak...

Pro spojité m.v. X, Y definujeme podmíněnou hustotu předpisem:

$$f_{X|Y}(x|y) = \frac{f_{XY}(x,y)}{f_Y(y)}$$

pokud je $f_Y(y) > 0$, jítak navrhujeme

$$= \frac{f_{XY}(x,y)}{\int f_{XY}(x,y) dx}$$

analogie s diskrétními veličinami,
vydělením $f_Y(y)$ "zafixujeme" y a
"scítáme" tak přes x


Kovariance

Pro m.v. X, Y definujeme jejich kovariaci předpisem:

$$\text{cov}(X,Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

$$X - \mathbb{E}X = \begin{cases} + & \dots x > \mathbb{E}X \\ - & \dots x < \mathbb{E}X \end{cases}$$

$\mathbb{E}Y -$ analogicky



Korelace

Korelace m.v. X, Y je definována předpisem:

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}} \quad \text{někdy se značí } \rho(X, Y)$$

korelace je prenormovaná kovariance tak, aby:

$$-1 \leq \text{corr}(X, Y) \leq 1$$

vime:

$$\text{corr}(X, Y) = \begin{cases} 1 & \text{pro } X = Y \\ (-1, 1) & \text{jimak} \\ -1 & \text{pro } X = -Y \end{cases}$$

Momentová vytvárající funkce

Pro měřidelnou veličinu X označíme $M_X(t) = \mathbb{E}(e^{(tX)})$

Funkci $M_X(t)$ nazýváme momentová vytvárající funkce.

Empirická distribuční funkce


Pro m.m.v. $x_1, \dots, x_m \sim F$, kde F je jejich distribuční fce

je definována pomocí indikátorové veličiny $I(x_i \leq x) = \begin{cases} 1 & \text{pokud } (x_i \leq x) \\ 0 & \text{jimak} \end{cases}$

míšledoumě:

$$\hat{F}_m(x) = \frac{\sum_{i=1}^m I(x_i \leq x)}{m}$$

dává smysl, zároveň
výsledky pokusu



$$\hat{F}_m(x) = \frac{\# \text{ tref do intervalu}}{\# \text{ všech pokusů}} = \underline{\underline{\text{podíl úspěšných pokusů}}}$$

Dodový odhad

odhad $\widehat{\Theta}_m = \widehat{\Theta}_m(x_1, \dots, x_m)$ parametru θ je:

umělošed

$$\text{mezaujatý} \Leftrightarrow \theta = \bar{E}(\widehat{\Theta}_m) \rightarrow \text{tedy } \bar{E}(\widehat{\Theta}_m) - \theta = 0$$

asymptoticky

$$\text{mezaujatý} \Leftrightarrow \theta = \lim_{m \rightarrow \infty} \bar{E}(\widehat{\Theta}_m) - \theta \rightarrow \text{tedy } \bar{E}(\widehat{\Theta}_m) - \theta \xrightarrow{\lim} 0$$

konzistentní

$$\Leftrightarrow \widehat{\Theta}_m \rightarrow \theta \left\{ \begin{array}{l} \text{skoro jisté} \\ \text{v pravděpodobnosti} \end{array} \right.$$

BIAS

$$\text{bias}_{\theta}(\widehat{\Theta}_m) = \left\{ \begin{array}{l} \bar{E}(\widetilde{\Theta}_m) \rightarrow \bar{E}(\text{odhad}) \\ \bar{E}(\widehat{\Theta}_m) - \theta \rightarrow \bar{E}(\text{odhad}) - \text{návěřená hodnota} \end{array} \right\}$$

jsou si rovný podle linearity E

MSE střední kvadratická chyba

$$MSE = E((\hat{\Theta} - \Theta)^2) = E(\text{bias}_\Theta(\hat{\Theta}))^2$$

Metoda momentů

r-tý moment

$$m_r(\Theta) = E(x^r), X \sim F_\Theta$$

r-tý výběrový moment

$$\widehat{m}_r(\Theta) = \frac{1}{n} \sum_{i=1}^n (x_i)^r, x_1, \dots, x_n \text{ náhodný výběr z } F_\Theta$$

Metoda maximální věrohodnosti - úvod

máme:

máhodný výber

$$X = (x_1, \dots, x_m), x_1, \dots, x_m \sim F_{\theta}$$

mohoucí výsledek

$$x = (x_1, \dots, x_m)$$

pro nějaké $w \in \Omega$: $x_1 = y_1(w)$
 $x_2 = y_2(w)$
...

fci:

$$\left\{ \begin{array}{l} \text{sdržená prst. fce. } P_X(x, \omega) \\ \text{sdržená hustotní fce } f_X(x, \omega) \end{array} \right.$$

věrohodnost: \rightarrow je to jem značení abydlo
nemůže řešit disk. x spon.

$$L(x, \omega) = \begin{cases} P_X(x, \omega) \\ f_X(x, \omega) \end{cases}$$

využití:

obvykle máme Θ

$\Rightarrow L(x, \omega)$ je funkce x

může být obrácené: máme x

$= L(x, \omega)$ je funkce Θ

metoda:

Volíme takové Θ , pro které
 $L(x, \omega)$ maximální.

Metoda maximální věrohodnosti - def.

metoda

Volíme takové θ , pro které je $L(x, \theta)$ maximální

definujeme také:

$$l(x, \theta) = \log(L(x, \theta))$$

díky mezinávislosti platí:

$$L(x, \theta) = P_x(x, \theta) = P_x((x_1, \dots, x_m), \theta) = \prod_{i=1}^m P_x(x_i, \theta)$$

$$l(x, \theta) = \sum_{i=1}^m \log(P_x(x_i, \theta)) \quad \text{⊗ Log součinu = součet Log}$$

$$\text{⊗ Log je rostoucí fce} \Rightarrow \max\{l(x, \theta)\} = \max\{L(x, \theta)\}$$

Intervalové odhady

místo jednoho čísla vypočítáme z dat interval $[\hat{H}^-, \hat{H}^+]$

Nechť jsou \hat{H}^- , \hat{H}^+ náhodná vel., které závisí na mál. výběru $X = (X_1, \dots, X_m)$

Tyto M.V. určují intervalový odhad, též **konfidenční interval**

○ spolehlivost: $1-\delta$, pokud:

$$P(\hat{H}^- \leq \theta \leq \hat{H}^+) \geq 1-\delta$$

Studentovo t-rozdělení

$$\bar{X}_m = \frac{1}{m} \sum_{i=1}^m X_i \dots \text{výběrový průměr}$$

$$\hat{s}_m^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X}_m)^2 \dots \text{výběrový rozptyl}$$

nechť $X_1, \dots, X_m \sim N(\mu, \sigma^2)$, potom:

$$\frac{\bar{X}_m - \mu}{\frac{\sigma}{\sqrt{m}}} \sim N(0, 1)$$

studentovo t rozdělení s $m-1$ stupni volnosti je rozdělení M.V.

$$\frac{\bar{X}_m - \mu}{\frac{\sigma}{\sqrt{m}}}$$

závisí na μ
závisí na σ

(*) distribuční fce Ψ_{m-1}

platí: $\lim_{n \rightarrow \infty} \Psi_{n-1}(t) = \Phi(t)$

χ^2_k -rozdělení

$Z_1, \dots, Z_k \sim N(0,1)$ m.m.v. Rozdělení m.v.

$$Q = Z_{1,1}^2 + \dots + Z_{k,k}^2$$

se nazývá χ -kvadrát s k stupni volnosti

$$\mathbb{E}(Q) = k$$

$$\mathbb{E}(Q) = \mathbb{E}\left[\sum_{i=1}^k Z_i^2\right] = \sum_{i=1}^k \mathbb{E}(Z_i^2) = \sum_{i=1}^k 1 = k$$

$$\text{var}(Q) = 2k$$

⊗ zbytečné práce

Q je pro velké k blíže $N(k, 2k)$ CLV

Multimomické a kategorialní rozdělení

Dány $p_1, \dots, p_k \geq 0$ tak, že $\sum_{i=1}^k p_i = 1$. n-krat zopakuji pokus, kdy může nastat jedna z k možností, z nichž i-tá má p_i $X_i :=$ kolikrát nastala i-tá možnost.

(X_1, \dots, X_k) má multimomické rozdělení s parametry $n, (p_1, \dots, p_k)$

$$P(X_1=x_1, \dots, X_k=x_k) = \binom{n}{x_1, \dots, x_k} p_1^{x_1} \cdot \dots \cdot p_k^{x_k}$$

$$X_i \sim \text{Binom}(n, p_i)$$

Pearsonova χ^2 statistika

(x_1, \dots, x_k) multinomické rozdělení s parametry $m_i, (p_1, \dots, p_k)$

$$E_i := E(x_i) = m_i p_i \quad X_i \sim \text{Binom}(m_i, p_i)$$

Pearsonova χ^2 statistika je funkce:

$$\chi^2 := \sum_{i=1}^k \frac{(x_i - E_i)^2}{E_i}$$

Test dobré shody

$(X_1, \dots, X_k) \sim \text{Multinom}(m, (\pi_1, \dots, \pi_k))$, m známe, π neznáme

Hypotéza $H_0: \pi = \pi^*$
nějaké hodnoty

$$\bar{E}_i := m \pi_i^*, \quad \downarrow$$

Použijeme statistiku $T = \sum_{i=1}^k \frac{(X_i - \bar{E}_i)^2}{\bar{E}_i}$

Hypotézu H_0 zamítame, pokud $\underline{T} > \gamma$

$$\gamma := F_Q^{-1}(1-\alpha), \quad Q \sim \chi_{n-k}^2$$

$$P(\text{chyby 1. druhu}) = P(T > \gamma; H_0) \xrightarrow{n \rightarrow \infty} P(Q > \gamma) = \alpha$$

Lineární regrese

Máme data $(x_i, y_i), i=1, \dots, m$, chceme je proložit přímkou $y = \theta_0 + \theta_1 x$

tak, aby dom minimalizovali výraz

$$\sum_{i=1}^m (y_i - (\theta_0 + \theta_1 x_i))^2$$

kvadratická odlehlka

optimální parametry

$$\hat{\theta}_1 \sim \frac{\text{kovariance}}{\text{variance}} \quad \hat{\theta}_0 \sim \frac{\sum_{i=1}^m (x_i - \bar{x}_m)(y_i - \bar{y}_m)}{\sum_{i=1}^m (x_i - \bar{x}_m)^2}$$

\sim korelace

\bar{x}_m, \bar{y}_m = výběrové průměry

$$\hat{\theta}_0 = \bar{y}_m - \hat{\theta}_1 \bar{x}_m$$

model

$$y_i = \underbrace{\theta_0 + \theta_1 x_i}_{\text{ideální}} + \underbrace{w_i}_{\text{chyba}}, w_i \sim N(0, \sigma^2), w_1, \dots, w_m \text{ nezávislé}$$

met. Max. věr.

$$L(y; \theta) = \prod_{i=1}^m \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(y_i - \theta_0 - \theta_1 x_i)^2}{2\sigma^2}}$$

$L = \log(L)$

$$\ell(y, \theta) = a - b \sum_{i=1}^m (y_i - \theta_0 - \theta_1 x_i)^2$$


konstantní část $e^{(-\dots)}$

jen toto si de minimizovat

Bayesovská metoda - popis

- neznámý parametr považujeme za náhodnou veličinu Θ
- zvolíme apriorní distribuci, neboli hustotu pravděpodobnosti $f_{\Theta}(\theta)$ meziústlou na datech
- zvolíme statistický model $f_{X|\Theta}(x|\theta)$, který popisuje co měříme (pravděpodobnost s jakou to měříme) v závislosti na parametru θ
- pozorujeme hodnotu $X=x$ a potom spočítáme posteriorní distribuci $f_{\Theta|X}(\theta|x)$
- z té pak odvodíme co potřebujeme, mpr.
majde me a, b aby:

$$\int_a^b f_{\Theta|X}(\theta|x) d\theta \geq 1-\alpha$$



Bayesovské bodové odhady

MAP Maximum Aposteriori

Volíme $\hat{\theta}$ tak, aby maximalizovalo

* vlastnost

$P(\theta = \hat{\theta} | x=x)$ je největší možná

$$\left\{ \begin{array}{l} P_{(\Theta|x)}(\theta|x) \text{ pro diskrétní} \\ f_{(\Theta|x)}(\theta|x) \text{ pro spojité} \end{array} \right.$$

LMS Least mean square

Volíme $\hat{\theta} = E(\theta | x=x)$

* jsme ve střední hodnotě, kde bude minimalizovat kvadratickou odchylku
měřené hodnoty od θ

