

# Pravděpodobnost & statistika 1

## shrnutí!

### Nekonečné řady

#### Součet nekonečné řady

$\sum_{n=1}^{\infty} (a_n)$ , má smysl pokud

$$\lim_{n \rightarrow \infty} (a_n) = 0$$

nutná podmínka  
konvergence řady

#### "částeční sčítanci"

$$s_1 = a_1$$

$$s_2 = a_1 + a_2$$

$\vdots$

$$s_m = a_1 + \dots + a_m$$

řadu si rozdělíme  
na posloupnost  
částečných sčítanců,  
pokud má tato řada  
vlastní limitu, je tato  
limita = součet řady

$$\text{Pokud: } \lim_{n \rightarrow \infty} (s_n) = A \in \mathbb{R} \quad \Rightarrow \quad \sum_{n=1}^{\infty} (a_n) = A$$

# Geometrické řady

## Součet nekonečné geometrické řady

$$\sum_{n=1}^{\infty} (a_n) = a_1 + a_1 \cdot q + \dots + a_1 \cdot q^k + \dots, \quad \text{opět, pokud } \lim_{n \rightarrow \infty} (a_n) = 0$$

→ platí pouze, pokud  $q \in (-1, 1)$

## Částeční součty

$$S_1 = a_1$$

$$S_2 = a_1 + a_1 \cdot q$$

⋮

$$S_n = a_1 \cdot \frac{q^n - 1}{q - 1}$$

✓ tento výraz se mění pouze číselník, proto:  
pro  $|q| > 1$  jde výraz  $\rightarrow \infty$ , proto musí  
 $q \in (-1, 1)$

pokud:  $\lim_{n \rightarrow \infty} \left( a_1 \cdot \frac{q^n - 1}{q - 1} \right) = a_1 \cdot \frac{0 - 1}{q - 1} = a_1 \cdot \frac{1}{1 - q} = \frac{a_1}{1 - q} \Rightarrow \underline{\underline{\sum (a_n) = \frac{a_1}{1 - q}}}$

TODO:

- 1) střední hodnota [přednáška 4.]
- 2) rozptyl [přednáška 4.]
- 3) spojité n. veličiny [přednáška 5.]
- 4) podmíněná hustota a střední hodnota [přednáška 7.]

## Statistika - předpoklady zkoumaných úloh

- vždy předpokládáme **nezávislá** měření - hodnoty n.m.v.  $X_1, \dots, X_n \sim F$
- předpokládáme, že  $F$  patří do nějakého **modelu** = množiny distrib. fci s konečnou  $\mathbb{E}$
- můžeme potkat parametrické / neparametrické modely

param:

$$F \in \{ \text{d.f. } N(\mu, \sigma^2) \}$$

$$F \in \{ \text{d.f. } \text{Exp}(\lambda) \}$$

...

neparam:

empirická dist. fce

⊗ víc si uvádět nebudeme

## Statistika - měření

$$\{F_{\theta}, \theta \in \Theta\}$$

$F_{\theta} = \text{model}$

$\theta = \text{parametr}$

$\Theta = \text{množina}$

$\theta = \text{malá theta}$   
 $\Theta = \text{velká theta}$

---

## Statistika - metody

$\left\{ \begin{array}{l} \text{klasické} \\ \text{Bayesovské} \end{array} \right. \rightarrow \text{existuje neznámá konst. } \theta \text{ a my ji určujeme z mal. měření}$

$\rightarrow \theta$  je náhodná, pomocí Bayesovy věty pak upravujeme naše poznání o distribuci  $\theta$

# Statistika - cíle

- bodové odhady

→ určete  $\mu$

→ určete  $g(\mu)$  pro nějakou fci  $g$  např. rozptyl, který je závislý na  $g$

- intervalové odhady

→ odpovídáme intervalem, kterému náleží  $\mu$   $\mu \in (a, b)$

- testování hypotéz

→ je mince spravedlivá?

- Lineární regrese

→ data s dvěma číselnými hodnotami chápou jako souřadnice  
a prokládám je přímkou


→ zkoumáme jejich závislost

$$y = \beta_0 + \beta_1 x$$

průměr  
s osou  $y$

náklon

$$\begin{cases} > 0 & \nearrow & \dots \nearrow \\ = 0 & \rightarrow & \dots \rightarrow \\ < 0 & \searrow & \dots \searrow \end{cases}$$



## Bodové odhady a jejich vlastnosti

Pozorování:  $X = (X_1, \dots, X_n)$ ,  $X_i$  je n.m.v. s dist. fci  $F_{\theta}$

odhad je n.v.  $\hat{H} = \hat{H}_n = g(X)$ , pro vhodnou fci  $g$   
 $\neq H$  ... možná  
závislá na  $\theta \in H$

chyba odhadu

$$\text{je n.v. } \underbrace{\tilde{H}}_{\text{chyba}} = \underbrace{\hat{H}_n}_{\text{odhad}} := \underbrace{\hat{H}_n}_{\text{odhad}} - \underbrace{\theta}_{\text{skutečnost}}$$

BIAS = "zaujatost"

je konstanta  
(pro pevnou  $\theta$ )

$$b_{\theta}(\hat{H}_n) = E(\tilde{H}_n) \stackrel{\text{linearita } E}{=} E(\hat{H}_n) - \theta$$

řekáme, že odhad  $\hat{\theta}_n$  je

unbiased

nezaújatý

$$\Leftrightarrow b_{\theta}(\tilde{\theta}_n) = 0, \quad \forall \theta \in \Theta \quad \rightarrow \text{nemá chybu v měření}$$

asymptoticky

nezaújatý

$$\Leftrightarrow b_{\theta}(\tilde{\theta}_n) \rightarrow 0, \quad \forall \theta \in \Theta \quad \rightarrow \text{má chybu, která s postupem času klesá}$$

konzistentní  $\Leftrightarrow \hat{\theta}_n \xrightarrow{P} \theta, \quad \forall \theta \in \Theta$

$$\Leftrightarrow P(|\hat{\theta}_n - \theta| > \epsilon) \rightarrow 0, \quad \forall \epsilon > 0$$



## Testování hypotéz - ilustrace

hypotéza  $\begin{cases} H_0 \text{ nulová} \\ H_1 \text{ alternativní} \end{cases} \Rightarrow$  výsledek  $\begin{cases} \text{zamítáme } H_0 \text{ (platí } H_1) \\ \text{nezamítáme } H_0 \end{cases}$

chyba  $\begin{cases} 1. \text{ druhu chybě přijetí} \\ 2. \text{ druhu chybě zamítnutí} \end{cases}$

Potřebujeme určit  $k$  takové, aby:

- $P(\text{chyba } 1) \leq \alpha$  (typicky 0,05)

- došlo k zamítnutí, pokud:  $\left| S - \frac{n}{2} \right| > k$

ilustrace na hodech mincí

# úspěchů je víc než  $k$  daleko  
od očekávané hodnoty



## Testování hypotéz - obecný postup

- 1) vybereme vhodný statistický model
- 2) zvolíme hladinu významnosti  $\alpha$  (typicky  $\alpha = 0,05$ )
- 3) určíme testovou statistiku  $\delta = h(x_1, \dots, x_n)$   $h$  je fce, kterou aplikujeme při testu
- 4) určíme kritický obor - množinu  $W$  (kdy zamítáme  $H_0$ )
- 5) naměříme  $x_1, \dots, x_n \approx \chi_1, \dots, \chi_n$
- 6) určíme rozhodovací pravidlo  
zamítáme  $H_0$  pokud  $h(x_1, \dots, x_n) \in W$

\* často nejprve spočítáme hodnotu ... minimální  $\alpha$ , kdy zamítáme  $H_0$  místo toho, abychom určovali  $\alpha$  "dopředu"

# Bayesova věta

## • pro jevy

$B_1, B_2, \dots$  rozklad  $\Omega$ ,  $A \in \mathcal{F}$ ,  $P(A) > 0$  :

(\*)

$P(B_i) = \text{apriorní}$

nic o  $B_i$  zatím nemáme

$P(B_i|A) = \text{posteriorní}$

$B_i$  ... vycházíme z naměřených dat  $A$

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_j P(A|B_j)P(B_j)}$$

(\*) podíl "mého podm. jevu"  
ze  $\forall$  podm. jevu

## • pro diskrétní n.v.

$X, Y$  diskrétní n.v.

$$P_{Y|X}(y|x) = \frac{P_{X,Y}(x,y)P_Y(y)}{\sum_{y'} P_{X,Y}(x,y')P_Y(y')}$$

## • pro spojité n.v.

