

Prauděpodobnost & statistika 1

Véty

Základní vlastnosti:

V pravděpodobnostním prostoru (Ω, \mathcal{F}, P) platí pro $A, B \in \mathcal{F}$:

1) $P(A) + P(A^c) = 1$

2) $A \subseteq B \Rightarrow P(A) \leq P(B)$

3) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

4) $P(A_1 \cup A_2 \cup \dots) \leq \sum_{i=1}^{\infty} P(A_i)$ (subadditivita, Booleova nerovnost) (*) A_i nemusí být disjunktní


dk

1) $\Omega = A \cup A^c$

$$1 = P(\Omega) = P(A) + P(A^c)$$

2) $B = A \cup (B \setminus A)$ protože $A \subseteq B$

$$P(B) = P(A) + \underbrace{P(B \setminus A)}_{\geq 0} \geq P(A)$$



3)

$$P(A) = P(A \setminus B) \cup P(A \cap B)$$

$$P(B) = P(B \setminus A) \cup P(A \cap B)$$

 \Rightarrow

$$\begin{aligned} P(A \cup B) &= \overbrace{P(A \setminus B) \cup P(A \cap B)} + \overbrace{P(B \setminus A) \cup P(A \cap B)} - P(A \cap B) \\ &= P(A) + P(B) - P(A \cap B) \end{aligned}$$



4)

použijeme trik "zdisjunktivní"

$$B_1 = A_1$$

$$B_2 = A_2 \setminus A_1$$

$$B_3 = A_3 \setminus A_2$$

 \dots

$$\rightarrow \boxed{B_i = A_i \setminus \bigcup_{j < i} A_j}$$

$$1) B_i \subseteq A_i$$

$$2) B_i \subseteq B_j = \emptyset \quad \forall i \neq j$$

$$3) \bigcup B_i = \bigcup A_i$$

$$\rightarrow P(\bigcup A_i) = P(\bigcup B_i) = \sum P(B_i) \leq \sum \underline{P(A_i)}$$



Závislost podmínování

Pokud $A_1, \dots, A_m \in F$ a $P(A_1 \cap \dots \cap A_m) > 0$, tak:

$$P(A_1 \cap A_2 \cap \dots \cap A_m) = P(A_1) P(A_2 | A_1) P(A_3 | A_1 \cap A_2) \dots P(A_m | A_1 \cap \dots \cap A_{m-1})$$

Dle definice P.P. RL

důsledek def. podm. pravd.:

$$P(A \cap B) = P(A|B) P(B)$$

$$P(A_1) P(A_2 | A_1) P(A_3 | A_1 \cap A_2) \dots P(A_m | A_1 \cap \dots \cap A_{m-1})$$

$$= \cancel{P(A_1)} \cdot \frac{\cancel{P(A_1 \cap A_2)}}{\cancel{P(A_1)}} \cdot \frac{\cancel{P(A_1 \cap A_2 \cap A_3)}}{\cancel{P(A_1 \cap A_2)}} \cdot \dots \cdot \frac{\cancel{P(A_1 \cap \dots \cap A_m)}}{\cancel{P(A_1 \cap \dots \cap A_{m-1})}}$$

$$= \underline{\underline{P(A_1 \cap \dots \cap A_m)}}$$



Rozklad Ω pro P


Pokud B_1, B_2, \dots je rozklad Ω a $A \in F$, tak:

$$P(A) = \sum (A | B_i) P(B_i)$$

Dk \geq definice $P \cdot P$. LR

důsledek def. podm. pravd.: :

$$P(A \cap B) = P(A | B) P(B)$$



$$\rightarrow A = \bigcup (A \cap B_i)$$

$$P(A) = \bigcup P(A \cap B_i) = \underline{\underline{\sum P(A | B_i) P(B_i)}}$$



Bayesova věta

Pokud B_1, B_2, \dots je rozklad Σ , $A \in \mathcal{F}$ a $P(A), P(B_i) > 0$, tak:

$$P(B_j | A) = \frac{P(A | B_j) P(B_j)}{\sum P(A | B_i) P(B_i)}$$

$= 1$

Dle pomocí věty o rozkladu Σ LR

$$P(B_j | A) = \frac{P(B_j \cap A)}{P(A)} = \frac{P(A \cap B_j)}{P(A)} = \frac{P(A | B_j) P(B_j)}{\sum P(A | B_i) P(B_i)}$$


takže platí

věta o rozkladu Σ



LOTUS

Pro reálnou fci g a diskrétní m.v. X je $g(X)$ také diskrétní m.v.



Pokud X je d.m.v a g je reálná fce, tak:

$$\mathbb{E}(Y) = \sum_{x \in \text{Im}(X)} g(x) P(X=x)$$

Dk

Preznačme: $y = g(x)$, $I = \text{Im}(X)$

$$\Rightarrow \text{Im}(Y) = g(I)$$

$$\text{z def: } \mathbb{E}(Y) = \sum_{y \in \text{Im}(Y)} y \cdot P(Y=y) = \sum_{y \in g(I)} y \cdot P(Y=y)$$

$$= \sum_{y \in g(I)} y \cdot \sum_{\substack{x \in I \\ g(x)=y}} P(X=x) = \sum_{x \in I} \left[\sum_{y \in g(I)} y \cdot P(X=x) \right] = \sum_{x \in I} [g(x)] \cdot P(X=x)$$

$$Y: \Omega \rightarrow \mathbb{R}$$

$$\text{Im } Y = g(\text{Im } X)$$

potřebujeme ověřit 2 podm. d.m.v.

$$1) \text{Im } Y \subseteq \text{Im } X$$

protože $\text{Im } X$ je spočetná,
je i $\text{Im } Y$ spočetná

$$2) Y^{-1}(y) = X^{-1}(g^{-1}(y))$$

$$= \bigcup X^{-1}(y)$$

$$g(x) = y, x \in \text{Im}(X)$$

což je spočetné sjednocení
a $X^{-1}(y) \in F$, což je množina
uzavřená na spočetné sjednocení

suma má jen 1 prvek, jinak by $g(x)$ měla fce.



Vlastnosti E

Nechť X, Y jsou diskrétní m.v. a $a, b \in \mathbb{R}$

1) Pokud $P(X \geq 0) = 1$ & $E(X) = 0$ tak $P(X=0) = 1$

tedy, pokud je X vždy meziaporna a stř. musí být $P(X=0)=1$ je 0

2) Pokud $E(X) \geq 0$ tak $P(X \geq 0) > 0$

3) $E(a \cdot X + b) = a \cdot E(X) + b$

4) $E(X + Y) = E(X) + E(Y)$

Dk

1) $E(X) = \sum_{x \in \Omega(X)} x \cdot P(X=x) = 0$

2) $E(X) = \sum_{x \in \Omega(X)} x \cdot P(X=x) \geq 0 \Rightarrow P(X \geq 0) > 0$ v soumě musí být meziap. scitanci

3) $g(x) = (a \cdot x + b)$ pomocí lotusu

$$\begin{aligned} \sum (a \cdot x + b) \cdot P(X=x) &= a \sum x \cdot P(X=x) + b \cdot \sum P(X=x) = a \underbrace{\sum x \cdot P(X=x)}_{E(X)} + b \underbrace{\sum P(X=x)}_1 \\ &= a \cdot E(X) + b \end{aligned}$$

$\Rightarrow E(X) = \sum g(x) P(X=x)$

4) $g(X, Y) = (X+Y)$, $\mathbb{E}(X+Y) = \sum_{x \in \text{Elm}(X)} \sum_{y \in \text{Elm}(Y)} (x+y) P(X=x, Y=y) = \sum x P(X=x, Y=y) + \sum y P(X=x, Y=y)$

$\hat{\text{veta}} \circ \bar{P}_{X,Y} \Rightarrow \bar{P}_X, \bar{P}_Y$

$$= \sum_{x \in \text{Elm}(X)} x \cdot \underbrace{\sum_{y \in \text{Elm}(Y)} P(X=x, Y=y)}_{\bar{P}(X=x)} + \sum_{y \in \text{Elm}(Y)} y \cdot \underbrace{\sum_{x \in \text{Elm}(X)} P(X=x, Y=y)}_{\bar{P}(Y=y)} = \sum_{x \in \text{Elm}(X)} x \cdot \bar{P}(X=x) + \sum_{y \in \text{Elm}(Y)} y \cdot \bar{P}(Y=y) = \underline{\bar{E}(X) + \bar{E}(Y)}$$

Rozklad Σ pro \mathbb{E}

Pokud B_1, B_2, \dots je rozklad Σ a $A \in \mathcal{F}$, tak:

$$\mathbb{E}(X) = \sum_{i=1,2,\dots} \mathbb{E}(X|B_i) P(B_i)$$

Vedoucí má součet smysl

* scháma $\rightarrow P(B_i) = 0$ povídá, že je ≥ 0

Dk $\mathbb{E}(X) = \sum_{i=1,2,\dots} \underbrace{\sum_{x \in \text{Elm}(X)} x P(X=x|B_i) \cdot P(B_i)}_{\text{def. podm. stř. hod.}} = \sum_{x \in \text{Elm}(X)} x \cdot \underbrace{\sum_i P(X=x|B_i) \cdot P(B_i)}_{\hat{\text{veta}} o rozkl. \Sigma \text{ pro } P = P(X=x)}$

$$= \sum_{x \in \text{Elm}(X)} x \cdot \bar{P}(X=x) = \underline{\underline{\mathbb{E}(X)}}$$

II. definice rozptylu

$$\text{var}(x) = \mathbb{E}((x - \mathbb{E}x)^2) = \mathbb{E}(x^2) - \mathbb{E}(x)^2$$

Dle pomocí linearity \mathbb{E} 

$$\mathbb{E}((x - \mathbb{E}x)^2) = \mathbb{E}(x^2 - 2x \cdot \mathbb{E}x + (\mathbb{E}x)^2)$$

* použijeme závěrčovou VOLE: $\mathbb{E}(ax + by + cz) = a\mathbb{E}(x) + b\mathbb{E}(y) + c\mathbb{E}(z)$
podle m:

$$\begin{aligned}\mathbb{E}(x^2 - 2\underbrace{\mathbb{E}x \cdot x}_{\text{komit}} + \underbrace{(\mathbb{E}x)^2}_{\text{komit}}) &= \mathbb{E}(x^2) - \underbrace{2\mathbb{E}x \cdot \mathbb{E}(x)}_{\text{komit}} + \underbrace{(\mathbb{E}x)^2}_{\text{komit}} = \mathbb{E}(x^2) - 2(\mathbb{E}x)^2 + \mathbb{E}(x)^2 \\ &= \underline{\mathbb{E}(x^2) - \mathbb{E}(x)^2}\end{aligned}$$



Obecmý už ovec $P_{X,Y} \rightarrow P_X, P_Y$

Mějme dis.-m.v. X, Y potom:

$$1) P_X(x) = P(X=x) = \sum_{y \in \text{elm}(Y)} P(X=x \& Y=y) = \sum_{y \in \text{elm}(Y)} P_{X,Y}(x,y) \quad \forall x \in \mathbb{R}$$

$$2) P_Y(y) = \sum_{x \in \text{elm}(X)} P_{X,Y}(x,y) \quad \forall y \in \mathbb{R}$$

Dk

$$P_X(x) = P(\{\omega \in \Omega : X(\omega) = x\}) = P\left(\bigcup_{y \in \text{elm}(Y)} \{\omega \in \Omega : X(\omega) = x \& Y(\omega) = y\}\right)$$

$$= \underbrace{\sum_{y \in \text{elm}(Y)} P(X=x \& Y=y)}$$



Funkce měř. veličinu

Nechť X, Y jsou m.v. na (Ω, \mathcal{F}, P) , a mechtí $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ je funkce. Potom je

$$Z = g(X, Y) \text{ m.v. na } (\Omega, \mathcal{F}, P), \text{ a platí: } Z(\omega) = g(Y(\omega), Y(\omega))$$

$$\hookrightarrow \mathbb{E}(Z) = \mathbb{E}(g(X, Y)) = \sum_{x \in \text{Im}(X)} \sum_{y \in \text{Im}(Y)} g(x, y) \underbrace{P(X=x, Y=y)}_{P_{X,Y}(x,y)}$$

Dk (jako Lotus)

Lineárita E

* disledek věty o řeš mř. vektoru

Pro m.v. X, Y a $a, b \in \mathbb{R}$ platí:

$$\mathbb{E}(ax + by) = a \cdot \mathbb{E}(X) + b \cdot \mathbb{E}(Y)$$

Dle pomocí věty o řeš mř. vektoru LR

$$g(x, y) = ax + by, \text{ potom:}$$

$$\mathbb{E}(ax + by) = \mathbb{E}(g(X, Y)) = \sum_{x \in \Omega(X)} \sum_{y \in \Omega(Y)} g(x, y) P(X=x, Y=y)$$

$$= \sum_{x \in \Omega(X)} \sum_{y \in \Omega(Y)} ax P(X=x, Y=y) + \sum_{y \in \Omega(Y)} \sum_{x \in \Omega(X)} by P(X=x, Y=y)$$

$$= a \cdot \sum_{x \in \Omega(X)} x \cdot \underbrace{\sum_{y \in \Omega(Y)} P(X=x, Y=y)}_{P(X=x)} + b \cdot \sum_{y \in \Omega(Y)} y \cdot \underbrace{\sum_{x \in \Omega(X)} P(X=x, Y=y)}_{P(Y=y)}$$

* $\sum_{y \in \Omega(Y)} P(X=x, Y=y) = P(X=x)$ $\sum_{x \in \Omega(X)} P(X=x, Y=y) = P(Y=y)$

$$= a \cdot \sum_{x \in \Omega_m(X)} x \cdot P(X=x) + b \cdot \sum_{y \in \Omega_m(Y)} y \cdot P(Y=y)$$

$$= \underbrace{a \cdot \mathbb{E}(X)} + b \cdot \mathbb{E}(Y)$$



Součin \mathbb{E} nezávislých m.v.

Pro nezávislé diskrétní m.v. X, Y platí:

$$\mathbb{E}(XY) = \mathbb{E}(X) \cdot \mathbb{E}(Y)$$

Dk

$$\begin{aligned} g(x,y) &= x \cdot y \\ \mathbb{E}(XY) &= \sum_{x \in \Omega_m(X)} \sum_{y \in \Omega_m(Y)} (x \cdot y) P(X=x, Y=y) = \sum_{x \in \Omega_m(X)} \sum_{y \in \Omega_m(Y)} x \cdot y \cdot P(X=x) \cdot P(Y=y) \end{aligned}$$

z nezávislosti

LOTUS

$$= \sum_{x \in \Omega_m(X)} x \cdot P(X=x) \cdot \sum_{y \in \Omega_m(Y)} y \cdot P(Y=y) = \underbrace{\mathbb{E}(X) \cdot \mathbb{E}(Y)}$$

*) $\mathbb{E}(X \cdot X) \neq \mathbb{E}X \cdot \mathbb{E}X$

skoro vždy je X závislá
na sobě

*) je to implikace, tříkále:
závislost $\rightarrow \mathbb{E}(X) \cdot \mathbb{E}(Y) = \mathbb{E}(XY)$

Zato:

$$\mathbb{E}(XY) = \mathbb{E}(X) \cdot \mathbb{E}(Y) \quad \cancel{\Rightarrow} \quad \text{nezávislost}$$



Součet mezinárodních m.v. "konvoluce"

Pokud X, Y jsou m.m.v., má jejich součet $Z = X + Y$ prostřední funkci:

$$P(Z=z) = \sum_{x \in \text{elm}(X)} P(X=x) \cdot P(Y=z-x)$$

Dk \Rightarrow je def. mezinárodnosti m.v. LR

Víme, že pro $Z = X + Y$ platí:

$$\{ \omega \in \Omega : Z(\omega) = z \} = \bigcup_{x \in \text{elm}(X)} \{ \omega \in \Omega : X(\omega) = x \ \& \ Y(\omega) = z-x \}$$

$$P(Z=z) = \sum_{x \in \text{elm}(X)} P(X=x, Y=z-x)$$

což platí obecně (tedy i pro závislé m.v.)

* pro X, Y nezávislá to ale jde přepsat jako:

$$\sum_{x \in \text{elm}(X)} P(X=x) \cdot P(Y=z-x)$$



Práce s hustotou

Nechť spojite m.v. X má hustotu f_X . Pak:

$$1) P(X=x) = 0 \text{ pro } \forall x \in \mathbb{R}$$

$$2) P(a \leq X \leq b) = \int_a^b f_X(t) dt \text{ pro } \forall a \leq b \in \mathbb{R}$$

Dk $\textcircled{1} \Rightarrow \textcircled{2} \Rightarrow \textcircled{1}$ triviálne pro $(a=b=x)$, protože integrál přes nulový interval = 0

1) LR podle věty o spojitosti pravděpodobnosti:


$$P(X=x) = \lim_{\epsilon \rightarrow 0^+} P(x-\epsilon < X \leq x) = \lim_{\epsilon \rightarrow 0^+} P(X \leq x) - P(X \leq x-\epsilon)$$

$$= \lim_{\epsilon \rightarrow 0^+} \int_{-\infty}^x f_X(k) dk - \int_{-\infty}^{x-\epsilon} f_X(k) dk = \lim_{\epsilon \rightarrow 0^+} \int_{x-\epsilon}^x f_X(x) dx \stackrel{\text{Podle nějaké věty z matematiky:}}{=} 0$$

2) LR

$$P(a \leq X \leq b) = P(X \leq b) - P(X \leq a) + \underbrace{P(X=a)}_{=0, \text{plýme k 1}}$$

$$= \int_{-\infty}^b f_X(x) dx - \int_{-\infty}^a f_X(x) dx = \int_a^b f_X(t) dt$$



Spojité LOTUS

Pokud je X s.m.v s hustotou f_X a g je reálná funkce, tak:

$$\mathbb{E}(g(X)) = \int_{-\infty}^{+\infty} g(x) \cdot f_X(x) \cdot dx$$


Dk

Vymekáváme kvůli složitosti, myšlenka:

$$\int_t^{t+E} f_X = P(t \leq X \leq t+E) \dots \text{odpovídá pravdě, že jsme blízko } t, \\ \text{poté by se množilo } g(x) \dots$$

Universalita uniformního rozdělení

Nechť F je rostoucí spojitá funkce s $\lim_{x \rightarrow -\infty} F_x(x) = 0$ a $\lim_{x \rightarrow +\infty} F_x(x) = 1$. Potom:



- 1) Nechť $U \sim U(0,1)$ a $X = F^{-1}(U)$. Pak F je distribuční funkcií X .
- 2) Nechť X je m.v. s distribuční fcií $F = F_X$. Pak $F(X) \sim U(0,1)$

je

$$F = \frac{1}{\pi} \arctg x + \frac{1}{2}$$

$$X \rightarrow F(X) = \frac{1}{\pi} \arctg X + \frac{1}{2}$$

"jak se mapuje":

$F(x) = P(X \leq x)$ z def \rightarrow mohli bychom si myslet, že $F(x) = P(X \leq x) = 1$ NEJDE

rozepsámo korektně:

$F(X(\omega)) = P(X \leq \underline{X(\omega)})$ $\rightarrow X$ mejsou stejná věc



to ale

NEJDE

Dk

1) $U \sim U(0,1), X = F^{-1}(U) \rightarrow F^{-1}$ je dobré def na $(0,1)$ \Rightarrow předpokladi pro F
 \Rightarrow def.

$$F_X(x) = P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F_X(x)) = F_U(F_X(x)) = F_X(x)$$

$$\Rightarrow \underline{F_X = F}$$



2)

X má d.fci F , $Y = F(X)$ chceme $Y \sim U(0,1)$

\Rightarrow def.

$$P_Y(y) = P(Y \leq y) = P(F(X) \leq y) \stackrel{\text{protože } F \text{ je rostoucí}}{=} P(X \leq F^{-1}(y)) = F_Y(F^{-1}(y)) = y$$

$$F_Y(y) = \begin{cases} 0 & \text{pro } y < 0 \\ 1 & \text{pro } y \geq 1 \end{cases} \quad \text{protože } Y = F(X) \dots \text{kůži dle vám! } F(X)$$

① \Rightarrow pokud umíme generovat m.v. $X \in (0,1)$, dokážeme vytvořit m.v. s lib. distribucí

② \Rightarrow když máme nějakou m.v. a "myslíme si" že má distribuci X_Y , tak ji do dané distribuci řeď dosadíme a otestujeme, že co vypadá má uniformní rozdělení

STOU

Sdržený spojity LOTUS

$$\mathbb{E}(g(x,y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x,y) \cdot f_{x,y}(x,y) dx dy$$

odvodíme: $\mathbb{E}(ax + by + c) = a \cdot \mathbb{E}(x) + b \cdot \mathbb{E}(y) + c$

$$\mathbb{E}(g(x,y)) = \iint_{-\infty}^{+\infty} (ax + by + c) \cdot f_{x,y}(x,y) dx dy = \underbrace{\iint_{-\infty}^{+\infty} ax \cdot f_{x,y}(x,y) dx dy}_{a \cdot \mathbb{E}(x)} + \underbrace{\iint_{-\infty}^{+\infty} by \cdot f_{x,y}(x,y) dx dy}_{b \cdot \mathbb{E}(y)} + \underbrace{\iint_{-\infty}^{+\infty} c \cdot f_{x,y}(x,y) dx dy}_{=c}$$

*b · E(y)
analogicky*

$$a \cdot \iint_{\substack{x=-\infty \\ y=-\infty}}^{+\infty} x \cdot f_{x,y}(x,y) dx dy = a \cdot \int_{x=-\infty}^{+\infty} x \cdot \left(\int_{y=-\infty}^{+\infty} f_{x,y}(x,y) dy \right) dx \sim P(x=x) = f_x(x)$$
$$= a \cdot \int_{x=-\infty}^{+\infty} x \cdot f_x(x) dx = a \cdot \mathbb{E}(x)$$

Nezávislé spojité m.v.

Nechť X, Y mají sdruženou hustotu $f_{X,Y}$. Následující tvrzení jsou ekvivalentní:

1) X, Y jsou nezávislé

2) $f_{X,Y}(x,y) = f_X(x) \cdot f_Y(y)$

dk

$\boxed{2 \Rightarrow 1}$ z def. nezávislosti spojitéch m.v. (LR)

$$F_{X,Y}(x,y) = \iiint_{-\infty \times -\infty}^x f_{X,Y}(st) ds dt = \iint_{-\infty \times -\infty}^x f_X(s) \cdot f_Y(t) ds dt = \int_{-\infty}^x f_X(s) ds \cdot \int_{-\infty}^y f_Y(t) dt$$

$$= \underline{F_X(x) \cdot F_Y(y)}$$

$\boxed{1 \Rightarrow 2}$

protože jsou nezávislé

$$F_{X,Y}(x,y) \stackrel{*}{=} \underline{F_X(x) \cdot F_Y(y)}$$

$$\frac{\partial^2}{\partial_x \partial_y} \bar{F} = \left[\frac{\partial}{\partial_x} \bar{F}_X(x) \right] \left[\frac{\partial}{\partial_y} \bar{F}_Y(y) \right] = \underline{f_X(x) \cdot f_Y(y)}$$

derivate podle obou proměnných

(*) derivujeme jen tam, kde je funkce spojitá
(jinde to nemá smysl)



Součed spojitéh m.v.

Nechť jsou X, Y spojité m.m.v. Pak $Z = X + Y$ je také spojita m.v.
a jej hustotu dostaneme jako konvoluci funkcií f_X, f_Y neboli:

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(u) \cdot f_Y(z-u) du$$

dk
Vymedlíme, ohodní diskrétnímu případu

Podmínkování

Rozklad Σ pro spojité X , říká:

$$f_X(x) = \sum_i f_{X|\mathcal{B}_i}(x) \cdot P(\mathcal{B}_i)$$

$$F_X(x) = \sum_i F_{X|\mathcal{B}_i}(x) \cdot P(\mathcal{B}_i)$$

Quototmi i distribucí fce
jdou zapsat pomocí rozboru
případů

dk

speciální příklad byl na cvičení: "dva algoritmy"

Podmíněná, sdrůžená a marginalní hustota

z definice:


$$f_{x|y}(x|y) = \underbrace{f_y(y)}_{\text{podmíněná}} \cdot \underbrace{f_{x|y}(x|y)}_{\text{marginalní}} \cdot \underbrace{f_y(y)}_{\text{sdrůžená}}$$

$$f_{x|y}(x|y) = \frac{f_{x,y}(x,y)}{f_y(y)}$$

změn.
větě:

$$f_x(x) = \int_{-\infty}^{\infty} f_{x|y}(x|y) \cdot f_y(y) dy$$

(B)



(I.P) dk

$$f_x(x) = \int_{-\infty}^{\infty} f_{x,y}(x,y) \cdot dy$$

výjde nám z definice
podm. hustoty,

pomocí ekvivalence

přejdeme k distribucím

fci a ukážeme, že

když integrujeme

očekávanou hustotu $f_x(x)$

fci ukáčeme dostaneme distribuci fci $F_x(x)$ a proto to platí

ekvivalentně:

$$F_x(x) = \iint_{-\infty}^{x, \infty} f_{x,y}(s,t) ds dt$$

* tolle je vlastně
integral přes mějakou
množinu B

tady integrujeme

$$= \iint_{-\infty}^{x, \infty} f_{x,y}(s,t) ds dt = P((x,y) \in B) = P(X \leq x) = F_x(x)$$



Spojite Bayesova věta

X, Y spojité m.v., sloužotami f_X, f_Y
a sdruženou hustotou $f_{X,Y}$

v diskrétním jeví chtěl:

$$P(A|B) \rightsquigarrow P(B|A)$$

myri! elčeme

$$f_{X|Y} \rightsquigarrow f_{Y|X}$$

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{\int_{y \in \mathbb{R}} f_{X,Y}(x,y') f_Y(y') dy'}$$

dk \geq definice podm. hustotní fce

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)} = \frac{f_{X,Y}(x,y) f_Y(y)}{\int_{y \in \mathbb{R}} f_{X,Y}(x,y') f_Y(y') dy'}$$

$$f_X(x) = \int_y f_{X,Y}(x,y) dy = \int_y f_{X,Y}(x,y) \cdot f_Y(y) dy$$

$$f_{X,Y}(x,y) = f_{X,Y}(x|y) \cdot f_Y(y)$$



druhá definice kovariance

$$\text{cov}(x, y) = \mathbb{E}(xy) - \mathbb{E}(x) \cdot \mathbb{E}(y)$$

dk  \approx definice kovariance a linearity \mathbb{E}

$$\text{cov}(x, y) = \mathbb{E}((x - \mathbb{E}(x)) \cdot (y - \mathbb{E}(y)))$$

$$= \mathbb{E}(xy - x\mathbb{E}(y) - y\mathbb{E}(x) + \mathbb{E}(x)\mathbb{E}(y))$$

$$= \mathbb{E}(xy) - \mathbb{E}(x \underbrace{\mathbb{E}(y)}_{\text{komst}}) - \mathbb{E}(y \underbrace{\mathbb{E}(x)}_{\text{komst}}) + \mathbb{E}(\underbrace{\mathbb{E}(x)}_{\text{komst}} \cdot \underbrace{\mathbb{E}(y)}_{\text{komst}})$$

$$= \mathbb{E}(xy) - \mathbb{E}(y)\mathbb{E}(x) - \mathbb{E}(x)\mathbb{E}(y) + \mathbb{E}(x)\mathbb{E}(y) \cdot (1)$$

$$= \mathbb{E}(xy) - \mathbb{E}(x)\mathbb{E}(y)$$

 $\overline{\text{proc}}$
konstanta???

$$\mathbb{E}(ax) = a \cdot \mathbb{E}(x)$$

komnatnou tedy
vytknu před
aplikaci "venkovní"
střední hodnoty

diskretky

- $\text{var}(x) = \text{cov}(x, x)$
- $\text{cov}(x, a \cdot y + bz + c) =$
 $= a \cdot \text{cov}(x, y) + b \cdot \text{cov}(x, z)$
- x, y nezávislé \Rightarrow
 $\text{cov}(x, y) = 0$

$$\mathbb{E}(xy) = \mathbb{E}(x) \cdot \mathbb{E}(y)$$

potom

$$\text{cov}(x, y) = \mathbb{E}(xy) - \mathbb{E}(x)\mathbb{E}(y) = 0$$

* užádali jste
pro diskretní
ale i pro
obecné



Rozptyl súčtu

Nechť $X = \sum_{i=1}^n X_i$, potom platí:

$$\text{var}(X) = \sum_{i=1}^n \sum_{j=1}^n \text{cov}(X_i, X_j) = \sum_{i=1}^n \text{var}(X_i) + \underbrace{\sum_{i \neq j} \text{cov}(X_i, X_j)}_{=0 \text{ pro } X_i, X_j \text{ nezávislé}}$$

Pro nezávislé m.v. speciálne platí:

$$\text{var}(X) = \sum_{i=1}^n \text{var}(X_i)$$

dk pro m.v. platí protože

dk (LR) substitute, det. rozptylu, zpětma substitute, definice kovariance

$$\text{označme } Y_i = (X_i - \mathbb{E}(X_i)), \quad Y = \sum_{i=1}^n Y_i = \sum_{i=1}^n X_i - \mathbb{E}(X_i)$$

$$\text{var}(X) = \mathbb{E}(Y^2) = \mathbb{E}((X - \mathbb{E}(X))^2)$$

zároučím:

$$= \mathbb{E}(Y^2) = \mathbb{E}\left(\sum_{i=1}^n Y_i \cdot \sum_{j=1}^n Y_j\right) = \sum_{i=1}^n \sum_{j=1}^n Y_i \cdot Y_j = \sum_{i=1}^n \sum_{j=1}^n (X_i - \mathbb{E}(X_i)) \cdot (X_j - \mathbb{E}(X_j)) = \sum_{i=1}^n \sum_{j=1}^n \text{cov}(X_i, X_j)$$

to funguje protože tím, že

sumy násobíme, méněm y^2

z definice kovariance



Caudyho meroumost

Nechť x, y mají koměmou střední hodnotu a rozptyl. Potom:

$$\mathbb{E}(xy) \leq \sqrt{\mathbb{E}(x^2)\mathbb{E}(y^2)} \quad \rightarrow \text{důsledek pro korelace: } -1 \leq \rho(x,y) \leq 1$$

dk řečnáška $\Rightarrow \sim 24$ min. WTF!

$\langle x, y \rangle := \mathbb{E}(xy)$... skalarní součin na velkém prostoru Ω mal. vel. $\in \Omega$

platí:

$$\langle x, x \rangle \geq 0$$

$$\mathbb{E}(x^2)$$

Jemšemova nerovnost




Nechť X má konečnou střední hodnotu a mechtě je g komvexní reálná fce.

Potom:

$$\mathbb{E}(g(X)) \geq g(\mathbb{E}(X))$$

dk



def. komvexní fce

$$\forall s \exists a, b: ax + b \leq g(x) \text{ a } as + b = g(s)$$

* pro komkávní fce platí
nerovnost obráceně

máhled:

$$g(x) = x^2 \Rightarrow \mathbb{E}(g(X)) \geq g(\mathbb{E}(X))$$

protože: $\text{var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 \geq 0$

podle 2. def. var

$$\text{mějme: } S = \mathbb{E}(X)$$

potom: $g(x) \geq ax + b \Rightarrow g(X) \geq aX + b \dots g(X(w)) \geq a(X(w)) + b$

$$\mathbb{E}(g(X)) \geq \mathbb{E}(ax + b) = \underbrace{a \cdot \mathbb{E}(X)}_{\text{Cin. } \mathbb{E}} + b = \underbrace{aS + b}_{S = \mathbb{E}(X)} = g(S) = g(\mathbb{E}(X))$$

komv.
fce.



Markovova nerovnost

Nechť $X > 0$. Potom:

$$P(X \geq a) \leq \frac{E(X)}{a}$$

dk ind. vel., substituce, aplikace E , zpětná substituce + linearita E LR

$I = [X \geq a]$... ind. m.v. jevu

$$E(I) = P(X \geq a)$$

$$I \leq \frac{X}{a} \rightarrow \omega \in \Omega \quad \left\{ \begin{array}{l} X(\omega) \geq a: \quad 1 \leq \frac{X(\omega)}{a} \\ X(\omega) < a: \quad 0 \leq \frac{X(\omega)}{a} \end{array} \right.$$

⊗ protože $X > 0$

$$E(I) \leq E\left(\frac{X}{a}\right)$$

$$P(X \geq a) \leq \frac{E(X)}{\underline{a}}$$




Čebyševova nerovnost

* koncentrací: nerovnost \rightarrow závisí se koncentrací
hodnot m.v. kolem její střední hodnoty

Nechť X má konečnou střední hodnotu μ a rozptyl σ^2 . Pak:

$$P(|X-\mu| \geq a \cdot \sigma) \leq \frac{1}{a^2}$$



dk dosadíme za γ , použijeme Markovovu ner.

$$\gamma = (X-\mu)^2 \geq 0 \quad \text{var}(X) = \mathbb{E}((X-\mathbb{E}(X))^2)$$

$$\mathbb{E}(\gamma) = \text{var}(X) = \sigma^2$$

$$P(|X-\mu| \geq a \cdot \sigma) = P(\gamma \geq (a \cdot \sigma)^2) \leq \frac{\mathbb{E}(\gamma)}{a^2 \cdot \sigma^2} = \frac{\sigma^2}{a^2 \cdot \sigma^2} = \frac{1}{a^2}$$

$P(X \geq a) \leq \frac{\mathbb{E}(X)}{a}$
Markov



Chernoffova nerovnost

Nechť $X = \sum_{i=1}^n X_i$, kde X_i jsou m.m.v. mítvající hodnoty $\pm 1 \Rightarrow$ pravděpodobnost $\frac{1}{2}$.

Pak pro $t > 0$ platí:

$$\Pr(X \leq -t) = \Pr(X \geq t) \leq e^{-\frac{t^2}{2\sigma^2}} \quad \leftarrow \frac{\sigma^2}{t^2} \text{ Česky}$$

bez dlekažku

Silný zákon velkých čísel

Nechť X_1, \dots, X_m jsou m.m.v. se střední hodnotou μ a rozptylem σ^2 .

Značme $S_m = \frac{(X_1 + \dots + X_m)}{m}$ tzv. **výberový průměr**. Pak platí:

$$\lim_{m \rightarrow \infty} S_m = \mu \quad \text{skoro jistě} \quad \rightarrow \quad P(\{\omega : \lim_{m \rightarrow \infty} S_m = \mu\}) = 1$$

(*) Říkame, že posloupnost S_m konverguje k μ skoro jistě.

mejdeme dokázat přímo kvůli mimořadnosti

Slabý zákon velkých čísel

"říká, když se blíží průměr" (k E)

Nechť X_1, \dots, X_m jsou M.M.V. se stř. hodnotou μ a rozptylem σ^2 .

Označme $S_m = \frac{X_1 + \dots + X_m}{m}$. Potom pro $\forall \varepsilon > 0$ platí:

$$\lim_{m \rightarrow \infty} P(|S_m - \mu| > \varepsilon) = 0$$

✓ říkáme, že S_m konverguje k μ v pravděpodobnosti

dk

$$P\left(|S_m - \mu| > \frac{\varepsilon \cdot \sigma_m}{\sigma_m}\right) \leq \frac{1}{\left(\frac{\varepsilon}{\sigma_m}\right)^2} = \frac{\sigma_m^2}{\varepsilon^2} = \frac{\sigma_m^2}{\underline{\underline{m \cdot \varepsilon^2}}} \quad \text{✓ } m \rightarrow \infty \text{ bude vždy } 0$$

protože $\sigma_m^2 = \text{var}(S_m) = \frac{m \cdot \sigma^2}{m^2} = \frac{\sigma^2}{m}$



Centrální limitní věta

"říká, k čemu se blíží průměr & jak je průměr střední hodnoty odchylky"

Nechť X_1, \dots, X_m jsou m.m.v. se střední hodnotou μ a rozptylem σ^2 .

$$\text{Definujme } Y_m = \frac{(X_1 + \dots + X_m) - m\mu}{\sqrt{m}} = \frac{\sum_{i=1}^m X_i - \sum_{i=1}^m \mu}{\sqrt{\sum_{i=1}^m \sigma^2}}$$

Pak pokud je F_m distribuční funkce Y_m , tak:

$$\lim_{m \rightarrow \infty} F_m(x) = \Phi(x) \quad \forall x \in \mathbb{R}$$

(*) Záležíme, že posloupnost Y_m konverguje k $N(0, 1)$ v distribuci

bez dělení

co mám to umožnit? nejjednodušším důsledkem věty je:

$$P(a \leq Y_m \leq b) \rightarrow \Phi(b) - \Phi(a)$$

což mám velmi zjednoduší výpočty

$$a = \frac{(X_1 + \dots + X_m) - m\mu}{\sqrt{m}} \leq b$$

$$\mu - \frac{a}{\sqrt{m}} \leq \frac{(X_1 + \dots + X_m)}{m} \leq \mu + \frac{b}{\sqrt{m}}$$

$$(X_1 + \dots + X_m) \leq \sqrt{m}b + m\mu$$

$$\frac{(X_1 + \dots + X_m)}{m} \leq \frac{b}{\sqrt{m}} + \mu$$

Poznámky k lim. větám

CLV

$$Y_m = \frac{(X_1 - \mu) + (X_2 - \mu) + \dots}{\sqrt{m}}$$

proč odčítáme μ ?

$$\mathbb{E}(X_i) = \mu$$

$$\mathbb{E}(X_i - \mu) = 0 \quad \dots \text{centrování}$$

každou X_i "vycentrujeme kolem muly"

získáme tak distribuci, která je stejně vychýlená na obě strany

proč dělíme \sqrt{m} ?

v limitním případě se Y_m v distribuci může blížit $N(0,1)$, že $\sigma^2 \sim 1$

$$\Rightarrow \frac{(X_1 + \dots + X_m) - m\mu}{\sqrt{m \cdot \sigma^2}} = \frac{(X_1 + \dots + X_m) - m\mu}{\sqrt{m}}$$

slaby ZVC

mluví o tom, že je čím dál
tím méně pravděpodobné,
že jsme "daleko" od $E(X)$

Vlastnosti empirické distrib. fce

Pro pevné x platí:

$$1) \quad \mathbb{E}(\hat{F}_m(x)) = F(x)$$

$$2) \quad \text{var}(\hat{F}_m(x)) = \frac{F(x)(1-F(x))}{m}$$

3) $\hat{F}_m(x) \xrightarrow{P} F(x)$... emp. dist. fce konverguje k $F(x)$ v pravděpodobnosti

dk

$$\hat{F}_m(x) = \frac{\sum_{i=1}^m I(X_i \leq x)}{m}$$

$$\text{Definice } Y_i = I(X_i \leq x)$$

$$S_m = \overline{Y_i} = \frac{Y_1 + \dots + Y_m}{m} = \hat{F}_m(x)$$

$$1) \quad \mathbb{E}(S_m) = \mathbb{E}(Y_i) = F(x) = \mu$$

$$2) \quad \mu = \mathbb{E}(S_m) = F(x)$$

2) protože $Y_i \sim \text{Bern}(\mu)$:

$$\text{var}(Y_i) = \mu(1-\mu)$$

potom $\hat{F}_m(x) \xrightarrow{P} F(x)$, podle zákonu velkých čísel

$$\text{var}(S_m) = \frac{\mu(1-\mu)}{m}$$



DKW (Dvoretzky-Kiefer-Wolfowitz)

Nechť $x_1, \dots, x_m \sim F$ jsou m.m.v. a \hat{F}_m je jejich EDF a měří je $\bar{E}(x_i)$ komečka.

Zvolme $\delta \in (0,1)$ a označme $\epsilon = \sqrt{\frac{1}{2m} \log\left(\frac{2}{\delta}\right)}$. Pak platí pro x :

$$P\left(\hat{F}_m(x) - \epsilon \leq F(x) \leq \hat{F}_m(x) + \epsilon\right) \geq 1 - \delta$$

$$\epsilon \rightarrow \frac{f(\delta)}{\sqrt{m}}$$

⊗ větší m , tím menší
 $\epsilon = tím$ přesnější výsledek
 (přičemž m je # pokusů)
 $x_1, \dots, x_{\underline{m}}$

bez dokazu

2. definice MSE

$$MSE = \text{bias}_\theta(\hat{\Theta}_m)^2 + \text{var}_\theta(\hat{\Theta}_m)$$

dk

$$\mu = \mathbb{E}(\hat{\Theta}_m)$$

$$MSE = \mathbb{E}\left((\hat{\Theta}_m - \underbrace{\mu + \mu - \nu}_{=0})^2\right) = \mathbb{E}\left((\hat{\Theta}_m - \mu)^2 + 2(\hat{\Theta}_m - \mu)(\mu - \nu) + (\mu - \nu)^2\right)$$

$$\stackrel{\text{LIM } \mathbb{E}}{=} \mathbb{E}((\hat{\Theta}_m - \mu)^2) + 2 \cdot \underbrace{\mathbb{E}(\hat{\Theta}_m - \mu)}_{\text{zvč}} \underbrace{(\mu - \nu)}_{\text{komst.}} + (\mu - \nu)^2$$

$$= \underbrace{\mathbb{E}((\hat{\Theta}_m - \mu)^2)}_{\mathbb{E}((x - \mathbb{E}x)^2)} + \underbrace{(\mu - \nu)^2}_{(\mathbb{E}(\hat{\Theta}) - \nu)^2} = \text{var}_\theta(\hat{\Theta}_m) + \text{bias}_\theta(\hat{\Theta}_m)^2$$

(*) dledech, pro malový bias, zedán odhad s co nejmenším rozptylem



Parametry výběrového momentu a rozptylu

1) \bar{X}_n je konsistentní měřitelný odhad $\mu = \mathbb{E}(x_i)$

$$\begin{aligned}\bar{X}_n &= \frac{1}{n} \cdot \sum_{i=1}^n x_i && \text{výběrový průměr} \\ \bar{S}_n &= \frac{1}{n} \cdot \sum_{i=1}^n (x_i - \bar{X}_n)^2 && \text{odhad} \mathbb{E} \\ \hat{S}_n &= \frac{1}{n-1} \cdot \sum_{i=1}^n (x_i - \bar{X}_n)^2 && \left. \begin{array}{l} \text{odhady} \\ \text{rozptylu} \end{array} \right\} \end{aligned}$$

2) \bar{S}_n je konsistentní asymptoticky měřitelný odhad $\sigma^2 = \text{var}(x_i)$

3) \hat{S}_n je konsistentní měřitelný odhad $\sigma^2 = \text{var}(x_i)$

dle

$$1) \quad \mathbb{E}(\bar{X}_n) = \frac{\mathbb{E}(x_1) + \dots + \mathbb{E}(x_n)}{n} = \mu \Rightarrow \text{je měřitelný}, \text{ podle záv. je konsistentní}$$

$$2) \quad \mathbb{E}(\bar{S}_n) = \mathbb{E} \frac{\sum_{i=1}^n (x_i - \bar{X}_n)^2}{n} \\ = \mathbb{E} \left(\frac{1}{n} \cdot \sum_{i=1}^n (x_i - \mu + \mu - \bar{X}_n)^2 \right) = \frac{1}{n} \sum_{i=1}^n ((x_i - \mu) - (\bar{X}_n - \mu))^2$$

$$= \mathbb{E} \left(\frac{1}{n} \sum_{i=1}^n ((x_i - \mu)^2 - 2(x_i - \mu)(\bar{X}_n - \mu) + (\bar{X}_n - \mu)^2) \right)$$

$$= \mathbb{E} \left(\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 - \frac{2}{n} (\bar{x}_n - \mu) \cdot \underbrace{\sum_{i=1}^n (x_i - \mu)}_{= n(\bar{x}_n - \mu)} - \frac{1}{n} \sum_{i=1}^n (\bar{x}_n - \mu)^2 \right)$$

$$= \mathbb{E} \left(\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 - \frac{2}{n} (\bar{x}_n - \mu) \cdot n(\bar{x}_n - \mu) + \frac{1}{n} \sum_{i=1}^n (\bar{x}_n - \mu)^2 \right)$$

$$= \mathbb{E} \left(\underbrace{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}_{\frac{1}{n} \cdot n(x_i - \mu)^2} - 2(\bar{x}_n - \mu)^2 + (\bar{x}_n - \mu)^2 \right) \underbrace{\frac{1}{n} \cdot n(\bar{x}_n - \mu)^2}$$

$$= \mathbb{E} \left((x_i - \mu)^2 - (\bar{x}_n - \mu)^2 \right)$$

$$= \mathbb{E}((x_i - \mu)^2) - \mathbb{E}((\bar{x}_n - \mu)^2)$$

$$= \text{var}(x_i) - \text{var}(\bar{x}_n)$$

$$= \sigma^2 - \frac{\sigma^2}{n}$$

$$= \frac{n-1}{n} \cdot \sigma^2$$

$$\text{var}(\bar{x}_n) = \text{var}\left(\frac{x_1 + \dots + x_n}{n}\right)$$

$$= \frac{1}{n^2} \sum_{i=1}^n \text{var}(x_i)$$

$$= \frac{1}{n^2} \cdot n \cdot \text{var}(x_i)$$

$$= \frac{\text{var}(x_i)}{n} = \frac{\sigma^2}{n}$$

3)

$$\mathbb{E}(\widehat{s}_m) = \underbrace{\frac{m}{m-1}}_{\text{Besselova korekce}} \cdot \underbrace{\frac{m-1}{m}}_{\mathbb{E}(s_m)} \cdot \sigma^2 = \underline{\underline{\sigma^2}}$$



vztah n-tých momentů

$\widehat{m}_r(\omega)$ je městřerný konzistentní odhad $m_r(\omega)$

dk

$$\mathbb{E}(\widehat{m}_r(\omega)) = \mathbb{E}\left(\frac{1}{m} \sum_{i=1}^m (x_i^r)\right) = \frac{1}{m} \sum_{i=1}^m \underbrace{\mathbb{E}(x_i^r)}_{m_r(\omega)} = \underline{\underline{m_r(\omega)}} \Rightarrow \text{městřerný}$$

Podle ZVČ pro (x_i^r) : $\widehat{m}_r(\omega) \xrightarrow[\text{stejně i stejně}]{} m_r(\omega)$ \Rightarrow konzistentní



* dá se spočítat: jako soustava rovnic

$$\underbrace{m_r(\omega)}_{\text{spočteme z } F_\omega} = \underbrace{\widehat{m}_r(\omega)}_{\text{spočteme z měřených dat}}$$

Intervalové odhady normální veličiny

Májme X_1, \dots, X_m malodny výběr z $N(\mu, \sigma^2)$. Zmáme Θ , chceme určit α .

$f \in (0,1)$. Nechť $\Phi(z_{\frac{f}{2}}) = 1 - \frac{f}{2}$ a $\widehat{\Theta}_m = \bar{X}_m$

$$C_m := \left[\widehat{\Theta}_m - z_{\frac{f}{2}} \cdot \frac{\sigma}{\sqrt{m}}, \widehat{\Theta}_m + z_{\frac{f}{2}} \cdot \frac{\sigma}{\sqrt{m}} \right]$$

$$\text{Pak } P(C_m \ni \Theta) = 1 - f$$

$$P(Z > z_{\frac{f}{2}}) = \frac{f}{2}$$

$$Z \sim N(0,1)$$

dk

máme $X_1, \dots, X_m \sim N(\mu, \sigma^2) \Rightarrow \bar{X}_m \sim N(\mu, \frac{\sigma^2}{m})$ protože máme-li $X_1, X_2 \sim N(\mu, \sigma^2)$
· tak i $X_1 + X_2$ je normální
· $E(\bar{X}_m) = \mu$, $\text{var}(\bar{X}_m) = \frac{\sigma^2}{m}$

$$Z = \frac{\bar{X}_m - \mu}{\frac{\sigma}{\sqrt{m}}} \sim (0,1) \quad X = \mu + \sigma \cdot Z$$

$$Z = \frac{X - \mu}{\sigma}$$

$$P(Z \geq z_{\frac{f}{2}}) = \frac{f}{2} \quad \& \quad P(Z \leq -z_{\frac{f}{2}}) = \frac{f}{2}$$

$$P(|Z| \geq z_{\frac{f}{2}}) = f$$



$$P\left(\left|\frac{\bar{X}_m - \mu}{\frac{\sigma}{\sqrt{m}}}\right| \geq z_{\frac{f}{2}}\right) = f$$

$$P\left(|\bar{X}_m - \mu| \geq z_{\frac{f}{2}} \cdot \frac{\sigma}{\sqrt{m}}\right) = f$$

$$P\left(|\bar{X}_m - \mu| \leq z_{\frac{f}{2}} \cdot \frac{\sigma}{\sqrt{m}}\right) = 1 - f$$



Intervalové odhady pomocí CLV

Májme x_1, \dots, x_n malodmy výběr z rozdělením se střední hodnotou μ a rozptylem σ^2 .
Zmáme Φ , chceme určit $\forall f \in (0,1)$. Nechť $\bar{\Phi}(z_{\frac{f}{2}}) = 1 - \frac{f}{2}$. $\hat{H}_n = \bar{x}_n$

$$C_m := \left[\hat{H}_m - z_{\frac{f}{2}} \cdot \frac{\sigma}{\sqrt{m}}, \hat{H}_m + z_{\frac{f}{2}} \cdot \frac{\sigma}{\sqrt{m}} \right]$$

Pak $P(C_m \ni \vartheta) \rightarrow 1-f$ (limitně se blíží!)

dk

$$\bar{z}_m = \frac{\bar{x}_m - \vartheta}{\frac{\sigma}{\sqrt{m}}}, \quad \text{potom} \quad \bar{z}_m \xrightarrow{d} N(0,1) \quad \text{podle centrální limítnej věty}$$

díky tomu víme: $\lim_{n \rightarrow \infty} P(\bar{z}_m \geq z_{\frac{f}{2}}) = f$
 \rightarrow
 jako o větu výše
 \rightarrow

$$\lim_{n \rightarrow \infty} P(|\bar{x}_n - \vartheta| \leq z_{\frac{f}{2}} \cdot \frac{\sigma}{\sqrt{m}}) = 1-f$$

* pro dost velká n , ignorujeme
 že veličiny nemají $\sim N(\vartheta, \sigma^2)$,
 tímže používáme průměr
 se to tak "bude chovat"



Intervalové odhady pomocí studentova rozdělení

X_1, \dots, X_m je náhodný výběr z $N(\mu, \sigma^2)$. Chceme určit μ, σ **mezmaže**.

$f \in (0, 1)$. Nechť $\bar{\Psi}_{m-n}(z_{\frac{f}{2}}) = 1 - \frac{f}{2}$. $\hat{H}_m = \bar{X}_m$, $\hat{s}_m^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{X}_m)^2$

$$C_m := \left[\hat{H}_m - z_{\frac{f}{2}} \cdot \frac{\hat{s}_m}{\sqrt{m}}, \hat{H}_m + z_{\frac{f}{2}} \cdot \frac{\hat{s}_m}{\sqrt{m}} \right]$$

Pak $P(C_m \ni \mu) = 1 - f$

dk

$Z = \frac{\bar{X}_m - \mu}{\sqrt{\hat{s}_m^2}}$ má Studentovo t-rozdělení \rightarrow víme, že $\bar{\Psi}_{m-n}$ se lim. chová jako Φ

proto: $P(|Z| \geq z_{\frac{f}{2}}) = f$

→ jako v posl. 2 vět...

$$\underline{P\left(|\bar{X}_m - \mu| \leq z_{\frac{f}{2}} \cdot \frac{\hat{s}_m}{\sqrt{m}}\right) = 1 - f}$$



Pearsonové statistice

$$T \xrightarrow{d} \chi^2_{k-1}$$

když n je do mekomečma, blíží se k kvadrát

bez dk Platnost pro $k=2$:

$$k=2 \quad X_1 + X_2 = n \quad \text{protože je } n \text{ pokusu}$$

$$X_2 = n - X_1, \quad P_2 = n - P_1$$

$$P_1 + P_2 = 1$$

$$T = \sum_{i=1}^k \frac{(X_i - E_i)^2}{E_i} = \frac{(X_1 - \bar{E}(X_1))^2}{\bar{E}(X_1)} + \frac{(X_2 - \bar{E}(X_2))^2}{\bar{E}(X_2)}$$

$$= \frac{(X_1 - nP_1)^2}{nP_1} + \frac{(X_2 - nP_2)^2}{nP_2}$$

$$= \frac{(X_1 - nP_1)^2}{nP_1} + \frac{(n - X_1 - n(1 - P_1))^2}{nP_1}$$

$$= \frac{(X_1 - nP_1)^2}{nP_1} + \frac{(nP_1 - X_1)^2}{nP_1}$$

$$= \frac{(X_1 - nP_1)^2}{nP_1} + \frac{(X_1 - nP_1)^2}{nP_2} = \frac{(X_1 - nP_1)^2}{nP_1} + \frac{(X_1 - nP_2)^2}{nP_2}$$

$$= \frac{(X_1 - nP_1)^2 (P_2 + P_1)}{nP_1 P_2} = \left(\frac{(X_1 - nP_1)}{\sqrt{nP_1(1-P_1)}} \right)^2 = \left(\frac{(X_1 - \mu)}{\sigma} \right)^2 \xrightarrow{n \rightarrow \infty} N(0,1)$$

$$\begin{aligned} \text{vime } \mu &= \bar{E}(X_i) \\ \sigma^2 &= nP(1-P) \end{aligned}$$

Základní varianty Bayesovy věty

1) X spojita, Y diskrém.

$$P_{Y|X}(y|x) = \frac{f_{X|Y}(x|y) \cdot P_Y(y)}{\sum_{y' \in \text{Dom}(Y)} f_{X|Y}(x|y') \cdot P_Y(y')}$$

2) X diskrém., Y spojita

$$P_{Y|X}(y|x) = \frac{P_{X|Y}(x|y) \cdot f_Y(y)}{\int_{y \in \mathbb{R}} P_{X|Y}(x|y) \cdot f_Y(y) dy}$$

