

# Prauděpodobnost & statistika 1

Véty

## Základní vlastnosti:

V pravděpodobnostním prostoru  $(\Omega, \mathcal{F}, P)$  platí pro  $A, B \in \mathcal{F}$ :

1)  $P(A) + P(A^c) = 1$

2)  $A \subseteq B \Rightarrow P(A) \leq P(B)$

3)  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

4)  $P(A_1 \cup A_2 \cup \dots) \leq \sum_{i=1}^{\infty} P(A_i)$  (subadditivita, Booleova nerovnost) (\*) A<sub>i</sub> nemusí být disjunktní


dk

1)  $\Omega = A \cup A^c$

$$1 = P(\Omega) = P(A) + P(A^c)$$

2)  $B = A \cup (B \setminus A)$  protože  $A \subseteq B$

$$P(B) = P(A) + \underbrace{P(B \setminus A)}_{\geq 0} \geq P(A)$$



3)

$$P(A) = P(A \setminus B) \cup P(A \cap B)$$

$$P(B) = P(B \setminus A) \cup P(A \cap B)$$

 $\Rightarrow$ 

$$\begin{aligned} P(A \cup B) &= \overbrace{P(A \setminus B) \cup P(A \cap B)} + \overbrace{P(B \setminus A) \cup P(A \cap B)} - P(A \cap B) \\ &= P(A) + P(B) - P(A \cap B) \end{aligned}$$



4)

použijeme trik "zdisjunktivní"

$$B_1 = A_1$$

$$B_2 = A_2 \setminus A_1$$

$$B_3 = A_3 \setminus A_2$$

 $\dots$ 

$$\rightarrow \boxed{B_i = A_i \setminus \bigcup_{j < i} A_j}$$

$$1) B_i \subseteq A_i$$

$$2) B_i \subseteq B_j = \emptyset \quad \forall i \neq j$$

$$3) \bigcup B_i = \bigcup A_i$$

$$\rightarrow P(\bigcup A_i) = P(\bigcup B_i) = \sum P(B_i) \leq \sum \underline{P(A_i)}$$



## Závislost podmínování

Pokud  $A_1, \dots, A_m \in F$  a  $P(A_1 \cap \dots \cap A_m) > 0$ , tak:

$$P(A_1 \cap A_2 \cap \dots \cap A_m) = P(A_1) P(A_2 | A_1) P(A_3 | A_1 \cap A_2) \dots P(A_m | A_1 \cap \dots \cap A_{m-1})$$

Dle definice P.P. RL

důsledek def. podm. pravd.:

$$P(A \cap B) = P(A|B) P(B)$$

$$P(A_1) P(A_2 | A_1) P(A_3 | A_1 \cap A_2) \dots P(A_m | A_1 \cap \dots \cap A_{m-1})$$

$$= \cancel{P(A_1)} \cdot \frac{\cancel{P(A_1 \cap A_2)}}{\cancel{P(A_1)}} \cdot \frac{\cancel{P(A_1 \cap A_2 \cap A_3)}}{\cancel{P(A_1 \cap A_2)}} \cdot \dots \cdot \frac{\cancel{P(A_1 \cap \dots \cap A_m)}}{\cancel{P(A_1 \cap \dots \cap A_{m-1})}}$$

$$= \underline{\underline{P(A_1 \cap \dots \cap A_m)}}$$



## Rozklad $\Omega$ pro $P$


Pokud  $B_1, B_2, \dots$  je rozklad  $\Omega$  a  $A \in F$ , tak:

$$P(A) = \sum (A | B_i) P(B_i)$$

Dk  $\geq$  definice  $P \cdot P$ . LR

důsledek def. podm. pravd.: :

$$P(A \cap B) = P(A | B) P(B)$$



$$\rightarrow A = \bigcup (A \cap B_i)$$

$$P(A) = \bigcup P(A \cap B_i) = \underline{\underline{\sum P(A | B_i) P(B_i)}}$$



## Bayesova věta

Pokud  $B_1, B_2, \dots$  je rozklad  $\Sigma$ ,  $A \in \mathcal{F}$  a  $P(A), P(B_i) > 0$ , tak:

$$P(B_j | A) = \frac{P(A | B_j) P(B_j)}{\sum P(A | B_i) P(B_i)}$$

$= 1$

Dle pomocí věty o rozkladu  $\Sigma$  LR

$$P(B_j | A) = \frac{P(B_j \cap A)}{P(A)} = \frac{P(A \cap B_j)}{P(A)} = \frac{P(A | B_j) P(B_j)}{\sum P(A | B_i) P(B_i)}$$


takže platí

věta o rozkladu  $\Sigma$



## LOTUS

Pro reálnou fci  $g$  a diskrétní m.v.  $X$  je  $g(X)$  také diskrétní m.v.



Pokud  $X$  je d.m.v a  $g$  je reálná fce, tak:

$$\mathbb{E}(Y) = \sum_{x \in \text{Im}(X)} g(x) P(X=x)$$

## Dk

Preznačme:  $y = g(x)$ ,  $I = \text{Im}(X)$

$$\Rightarrow \text{Im}(Y) = g(I)$$

$$\text{z def: } \mathbb{E}(Y) = \sum_{y \in \text{Im}(Y)} y \cdot P(Y=y) = \sum_{y \in g(I)} y \cdot P(Y=y)$$

$$= \sum_{y \in g(I)} y \cdot \sum_{\substack{x \in I \\ g(x)=y}} P(X=x) = \sum_{x \in I} \left[ \sum_{y \in g(I)} y \cdot P(X=x) \right] = \sum_{x \in I} [g(x)] \cdot P(X=x)$$

$$Y: \Omega \rightarrow \mathbb{R}$$

$$\text{Im } Y = g(\text{Im } X)$$

potřebujeme ověřit 2 podm. d.m.v.

$$1) \text{Im } Y \subseteq \text{Im } X$$

protože  $\text{Im } X$  je spočetná,  
je i  $\text{Im } Y$  spočetná

$$2) Y^{-1}(y) = X^{-1}(g^{-1}(y))$$

$$= \bigcup X^{-1}(y)$$

$$g(x) = y, x \in \text{Im}(X)$$

což je spočetné sjednocení  
a  $X^{-1}(y) \in F$ , což je množina  
uzavřená na spočetné sjednocení

suma má jen 1 prvek, jinak by  $g(x)$  měla fce.



## Vlastnosti E

Nechť  $X, Y$  jsou diskrétní m.v. a  $a, b \in \mathbb{R}$

1) Pokud  $P(X \geq 0) = 1$  &  $E(X) = 0$  tak  $P(X=0) = 1$

tedy, pokud je  $X$  vždy meziaporna a stř. musí být  $P(X=0)=1$  je 0

2) Pokud  $E(X) \geq 0$  tak  $P(X \geq 0) > 0$

3)  $E(a \cdot X + b) = a \cdot E(X) + b$

4)  $E(X + Y) = E(X) + E(Y)$

## Dk

1)  $E(X) = \sum_{x \in \Omega(X)} x \cdot P(X=x) = 0$

2)  $E(X) = \sum_{x \in \Omega(X)} x \cdot P(X=x) \geq 0 \Rightarrow P(X \geq 0) > 0$  v soumě musí být meziap. scitanci

3)  $g(x) = (a \cdot x + b)$  pomocí lotusu

$$\begin{aligned} \sum (a \cdot x + b) \cdot P(X=x) &= a \sum x \cdot P(X=x) + b \cdot \sum P(X=x) = a \underbrace{\sum x \cdot P(X=x)}_{E(X)} + b \underbrace{\sum P(X=x)}_1 \\ &= a \cdot E(X) + b \end{aligned}$$

$\Rightarrow E(X) = \sum g(x) P(X=x)$

4) Linearität von  $E$ , pro  $a, b = 1$

$$g(x, y) = (x+y), \quad E(x+y) = \sum_{x \in \text{Im}(x)} \sum_{y \in \text{Im}(y)} (x+y) P(x=x, y=y) = \sum x P(x=x, y=y) + \sum y P(x=x, y=y)$$

## Rozklad $S_2$ pro $\bar{E}$

Pokud  $B_1, B_2, \dots$  je rozklad  $\Omega$  a  $A \in F$ , tak:

$$\mathbb{E}(X) = \sum_{i=1,2,\dots} \mathbb{E}(X|B_i) P(B_i)$$

Ved jokoli mä sõinet smysl

\* सर्वांगीन तथा  $\gamma(B_i) = 0$  परामर्शदाता का 0

dk

RL

def. podm. str. Cud.

$$\sum_{i=1,2,\dots} \mathbb{E}(X|B_i) P(B_i) = \sum_i \sum_{x \in \text{Im}(X)} x \cdot P(X=x|B_i) \cdot P(B_i) = \sum_i x \cdot \sum_{\substack{x \in \\ \text{Im}(X)}} P(X=x|B_i) \cdot P(B_i)$$

## II. definice rozptylu

$$\text{var}(x) = \mathbb{E}((x - \mathbb{E}x)^2) = \mathbb{E}(x^2) - \mathbb{E}(x)^2$$

Dle pomocí linearity  $\mathbb{E}$  

$$\mathbb{E}((x - \mathbb{E}x)^2) = \mathbb{E}(x^2 - 2x \cdot \mathbb{E}x + (\mathbb{E}x)^2)$$

\* použijeme závěrčovou VOLE:  $\mathbb{E}(ax + by + cz) = a\mathbb{E}(x) + b\mathbb{E}(y) + c\mathbb{E}(z)$   
podle m:

$$\begin{aligned}\mathbb{E}(x^2 - 2\underbrace{\mathbb{E}x \cdot x}_{\text{komit}} + \underbrace{(\mathbb{E}x)^2}_{\text{komit}}) &= \mathbb{E}(x^2) - \underbrace{2\mathbb{E}x \cdot \mathbb{E}(x)}_{\text{komit}} + \underbrace{(\mathbb{E}x)^2}_{\text{komit}} = \mathbb{E}(x^2) - 2(\mathbb{E}x)^2 + \mathbb{E}(x)^2 \\ &= \underline{\mathbb{E}(x^2) - \mathbb{E}(x)^2}\end{aligned}$$



Obecmý už ovec  $P_{X,Y} \rightarrow P_X, P_Y$

Mějme dis.-m.v.  $X, Y$  potom:

$$1) P_X(x) = P(X=x) = \sum_{y \in \text{elm}(Y)} P(X=x \& Y=y) = \sum_{y \in \text{elm}(Y)} P_{X,Y}(x,y) \quad \forall x \in \mathbb{R}$$

$$2) P_Y(y) = \sum_{x \in \text{elm}(X)} P_{X,Y}(x,y) \quad \forall y \in \mathbb{R}$$

Dk

$$P_X(x) = P(\{\omega \in \Omega : X(\omega) = x\}) = P\left(\bigcup_{y \in \text{elm}(Y)} \{\omega \in \Omega : X(\omega) = x \& Y(\omega) = y\}\right)$$

$$= \underbrace{\sum_{y \in \text{elm}(Y)} P(X=x \& Y=y)}$$



## Funkce měř. veličinu

Nechť  $X, Y$  jsou m.v. na  $(\Omega, \mathcal{F}, P)$ , a mechtí  $g: \mathbb{R}^2 \rightarrow \mathbb{R}$  je funkce. Potom je

$$Z = g(X, Y) \text{ m.v. na } (\Omega, \mathcal{F}, P), \text{ a platí: } Z(\omega) = g(Y(\omega), Y(\omega))$$

$$\hookrightarrow \mathbb{E}(Z) = \mathbb{E}(g(X, Y)) = \sum_{x \in \text{Im}(X)} \sum_{y \in \text{Im}(Y)} g(x, y) \underbrace{P(X=x, Y=y)}_{P_{X,Y}(x,y)}$$

Dk (jako Lotus)

## Lineárita E

\* disledek věty o řeš mř. vektoru

Pro m.v.  $X, Y$  a  $a, b \in \mathbb{R}$  platí:

$$\mathbb{E}(ax + by) = a \cdot \mathbb{E}(X) + b \cdot \mathbb{E}(Y)$$

Dle pomocí věty o řeš mř. vektoru LR

$$g(x, y) = ax + by, \text{ potom:}$$

$$\mathbb{E}(ax + by) = \mathbb{E}(g(X, Y)) = \sum_{x \in \Omega(X)} \sum_{y \in \Omega(Y)} g(x, y) P(X=x, Y=y)$$

$$= \sum_{x \in \Omega(X)} \sum_{y \in \Omega(Y)} ax P(X=x, Y=y) + \sum_{y \in \Omega(Y)} \sum_{x \in \Omega(X)} by P(X=x, Y=y)$$

$$= a \cdot \sum_{x \in \Omega(X)} x \cdot \underbrace{\sum_{y \in \Omega(Y)} P(X=x, Y=y)}_{P(X=x)} + b \cdot \sum_{y \in \Omega(Y)} y \cdot \underbrace{\sum_{x \in \Omega(X)} P(X=x, Y=y)}_{P(Y=y)}$$

\*  $\sum_{y \in \Omega(Y)} P(X=x, Y=y) = P(X=x)$   $\sum_{x \in \Omega(X)} P(X=x, Y=y) = P(Y=y)$

$$= a \cdot \sum_{x \in \Omega_m(X)} x \cdot P(X=x) + b \cdot \sum_{y \in \Omega_m(Y)} y \cdot P(Y=y)$$

$$= \underbrace{a \cdot \mathbb{E}(X)} + b \cdot \mathbb{E}(Y)$$



Součin  $\mathbb{E}$  nezávislých m.v.

Pro nezávislé diskrétní m.v.  $X, Y$  platí:

$$\mathbb{E}(XY) = \mathbb{E}(X) \cdot \mathbb{E}(Y)$$

Dk

$$\begin{aligned} g(x,y) &= x \cdot y \\ \mathbb{E}(XY) &= \sum_{x \in \Omega_m(X)} \sum_{y \in \Omega_m(Y)} (x \cdot y) P(X=x, Y=y) = \sum_{x \in \Omega_m(X)} \sum_{y \in \Omega_m(Y)} x \cdot y \cdot P(X=x) \cdot P(Y=y) \end{aligned}$$

z nezávislosti

LOTUS

$$= \sum_{x \in \Omega_m(X)} x \cdot P(X=x) \cdot \sum_{y \in \Omega_m(Y)} y \cdot P(Y=y) = \underbrace{\mathbb{E}(X) \cdot \mathbb{E}(Y)}$$

\*)  $\mathbb{E}(X \cdot X) \neq \mathbb{E}X \cdot \mathbb{E}X$

skoro vždy je  $X$  závislá  
na sobě

\*) je to implikace, tříkále:  
závislost  $\rightarrow \mathbb{E}(X) \cdot \mathbb{E}(Y) = \mathbb{E}(XY)$

zato:

$$\mathbb{E}(XY) = \mathbb{E}(X) \cdot \mathbb{E}(Y) \quad \cancel{\Rightarrow} \quad \text{nezávislost}$$



## Součet mezinárodních m.v. "konvoluce"

Pokud  $X, Y$  jsou m.m.v., má jejich součet  $Z = X + Y$  prostřední funkci:

$$P(Z=z) = \sum_{x \in \text{elm}(X)} P(X=x) \cdot P(Y=z-x)$$

Dk  $\Rightarrow$  je def. mezinárodnosti m.v.  $\text{LR}$

Víme, že pro  $Z = X + Y$  platí:

$$\{ \omega \in \Omega : Z(\omega) = z \} = \bigcup_{x \in \text{elm}(X)} \{ \omega \in \Omega : X(\omega) = x \ \& \ Y(\omega) = z-x \}$$

$$P(Z=z) = \sum_{x \in \text{elm}(X)} P(X=x, Y=z-x)$$

což platí obecně (tedy i pro závislé m.v.)

\* pro  $X, Y$  nezávislá to ale jde přepsat jako:

$$\sum_{x \in \text{elm}(X)} P(X=x) \cdot P(Y=z-x)$$



## Práce s hustotou

Nechť spojite m.v.  $X$  má hustotu  $f_X$ . Pak:

$$1) P(X=x) = 0 \text{ pro } \forall x \in \mathbb{R}$$

$$2) P(a \leq X \leq b) = \int_a^b f_X(t) dt \text{ pro } \forall a \leq b \in \mathbb{R}$$

Dk  $\textcircled{1} \Rightarrow \textcircled{2} \Rightarrow \textcircled{1}$  triviálne pro  $(a=b=x)$ , protože integrál přes nulový interval = 0

1)  $\textcircled{LR}$  podle věty o spojitosti pravděpodobnosti


$$P(X=x) = \lim_{\varepsilon \rightarrow 0^+} P(x-\varepsilon < X \leq x) = \lim_{\varepsilon \rightarrow 0^+} P(X \leq x) - P(X \leq x-\varepsilon)$$

$$= \lim_{\varepsilon \rightarrow 0^+} \int_{-\infty}^x f_X(k) dk - \int_{-\infty}^{x-\varepsilon} f_X(k) dk = \lim_{\varepsilon \rightarrow 0^+} \int_{x-\varepsilon}^x f_X(x) dx \stackrel{\text{Podle nějaké věty z matematiky}}{=} 0$$

2)  $\textcircled{LR}$

$$P(a \leq X \leq b) = P(X \leq b) - P(X \leq a) + \underbrace{P(X=a)}_{=0, \text{plýme k 1}}$$

$$= \int_{-\infty}^b f_X(x) dx - \int_{-\infty}^a f_X(x) dx = \int_a^b f_X(t) dt$$



## Spojité LOTUS

Pokud je  $X$  s.m.v s hustotou  $f_X$  a  $g$  je reálná funkce, tak:

$$\mathbb{E}(g(X)) = \int_{-\infty}^{+\infty} g(x) \cdot f_X(x) \cdot dx$$


Dk

Vymekáváme kvůli složitosti, myšlenka:

$$\int_t^{t+E} f_X = P(t \leq X \leq t+E) \dots \text{odpovídá pravdě, že jsme blízko } t, \\ \text{poté by se množilo } g(x) \dots$$

## Universalita uniformního rozdělení

Nechť  $F$  je rostoucí spojitá funkce s  $\lim_{x \rightarrow -\infty} F_x(x) = 0$  a  $\lim_{x \rightarrow +\infty} F_x(x) = 1$ . Potom:



- 1) Nechť  $U \sim U(0,1)$  a  $X = F^{-1}(U)$ . Pak  $F$  je distribuční funkcií  $X$ .
- 2) Nechť  $X$  je m.v. s distribuční fcií  $F = F_X$ . Pak  $F(X) \sim U(0,1)$

~~pro~~

$$F = \frac{1}{\pi} \arctg x + \frac{1}{2}$$


$$X \rightarrow F(X) = \frac{1}{\pi} \arctg X + \frac{1}{2}$$

"jak se mapuje":

$F(x) = P(X \leq x) \stackrel{\text{z def}}{=} \rightarrow$  možli výborem si myslit, že  $F(x) = P(X \leq x) = 1$  NEJDE

rozepsámo korektně:

$F(X(\omega)) = P(X \leq \underline{X(\omega)}) \rightarrow X$  mejsou stejná věc




to ale

NEJDE

Dk

1)  $U \sim U(0,1), X = F^{-1}(U) \rightarrow F^{-1}$  je dobré def na  $(0,1)$   $\Leftrightarrow$  předpokladi pro  $F$   
 $\Leftrightarrow$  def.

$$F_X(x) = P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F_X(x)) = F_U(F_X(x)) = F_X(x)$$

$$\Rightarrow \underline{F_X = F}$$


2)

$X$  má d.fci  $F$ ,  $Y = F(X)$  chceme  $Y \sim U(0,1)$

$\Leftrightarrow$  def.

$$P_Y(y) = P(Y \leq y) = P(F(X) \leq y) \stackrel{\text{protože } F \text{ je rostoucí}}{=} P(X \leq \underbrace{F^{-1}(y)}_{y \in (0,1)}) = F_y(F^{-1}(y)) = y$$

$\leftarrow$   $F_Y(y) = \begin{cases} 0 & \text{pro } y < 0 \\ 1 & \text{pro } y > 1 \end{cases}$  protože  $Y = F(X)$  .. kvůli chování  $F(X)$

①  $\Rightarrow$  pokud umíme generovat m.v.  $X \in (0,1)$ , dokážeme vytvořit m.v. s lib. distribucí

②  $\Rightarrow$  když máme nějakou m.v. a "myslíme si" že má distribuci  $X_Y$ , tak ji do dané distribuci řeď dosadíme a otestujeme, že co vypadá má uniformní rozdělení

## Sdržený spojity LOTUS

$$\mathbb{E}(g(x,y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x,y) \cdot f_{x,y}(x,y) dx dy$$

odvodíme:  $\mathbb{E}(ax + by + c) = a \cdot \mathbb{E}(x) + b \cdot \mathbb{E}(y) + c$

$$\mathbb{E}(g(x,y)) = \iint_{-\infty}^{+\infty} (ax + by + c) \cdot f_{x,y}(x,y) dx dy = \underbrace{\iint_{-\infty}^{+\infty} ax \cdot f_{x,y}(x,y) dx dy}_{a \cdot \mathbb{E}(x)} + \underbrace{\iint_{-\infty}^{+\infty} by \cdot f_{x,y}(x,y) dx dy}_{b \cdot \mathbb{E}(y)} + \underbrace{\iint_{-\infty}^{+\infty} c \cdot f_{x,y}(x,y) dx dy}_{=c}$$

*b · E(y)  
analogicky*

$$a \cdot \iint_{\substack{x=-\infty \\ y=-\infty}}^{+\infty} x \cdot f_{x,y}(x,y) dx dy = a \cdot \int_{x=-\infty}^{+\infty} x \cdot \underbrace{\int_{y=-\infty}^{+\infty} f_{x,y}(x,y) dy}_{\sim P(x=x)} dx = a \cdot \int_{x=-\infty}^{+\infty} x \cdot f_x(x) dx = a \cdot \mathbb{E}(x)$$

## Nezávislé spojité m.v.

Nechť  $X, Y$  mají sdruženou hustotu  $f_{X,Y}$ . Následující tvrzení jsou ekvivalentní:

1)  $X, Y$  jsou nezávislé

2)  $f_{X,Y}(x,y) = f_X(x) \cdot f_Y(y)$

dk

$\boxed{2 \Rightarrow 1}$  z def. nezávislosti spojitéch m.v. (LR)

$$F_{X,Y}(x,y) = \iiint_{-\infty \times -\infty}^x f_{X,Y}(st) ds dt = \iint_{-\infty \times -\infty}^x f_X(s) \cdot f_Y(t) ds dt = \int_{-\infty}^x f_X(s) ds \cdot \int_{-\infty}^y f_Y(t) dt$$

$$= \underline{F_X(x) \cdot F_Y(y)}$$

$\boxed{1 \Rightarrow 2}$

protože jsou nezávislé

$$F_{X,Y}(x,y) \stackrel{*}{=} \underline{F_X(x) \cdot F_Y(y)}$$

$$\frac{\partial^2}{\partial_x \partial_y} \bar{F} = \left[ \frac{\partial}{\partial_x} \bar{F}_X(x) \right] \left[ \frac{\partial}{\partial_y} \bar{F}_Y(y) \right] = \underline{f_X(x) \cdot f_Y(y)}$$

derivate podle obou proměnných

(\*) derivujeme jen tam, kde je funkce spojitá  
(jinde to nemá smysl)



## Součed spojitéh m.v.

Nechť jsou  $X, Y$  spojité m.m.v. Pak  $Z = X + Y$  je také spojita m.v.  
a jej hustotu dostaneme jako konvoluci funkcií  $f_X, f_Y$  neboli:

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(u) \cdot f_Y(z-u) du$$

dk  
Vymedlíme, ohodní diskrétnímu případu

## Podmínkování

Rozklad  $\Sigma$  pro spojité  $X, Y$ :

$$f_X(x) = \sum_i f_{X|\mathcal{B}_i}(x) \cdot P(\mathcal{B}_i)$$

$$F_X(x) = \sum_i F_{X|\mathcal{B}_i}(x) \cdot P(\mathcal{B}_i)$$

Quototmi i distribucemi tce  
jde u zapasat pomocí rozboru  
případů

dk

speciální příklad byl na cvičení: "dva algoritmy"

## Podmíněná, sdrůžená a marginalní hustota

z definice:


$$f_{x|y}(x|y) = \underbrace{f_y(y)}_{\text{podmíněná}} \cdot \underbrace{f_{x|y}(x|y)}_{\text{marginalní}} \cdot \underbrace{f_y(y)}_{\text{sdrůžená}}$$

$$f_{x|y}(x|y) = \frac{f_{x,y}(x,y)}{f_y(y)}$$

změn.  
větě:

$$f_x(x) = \int_{-\infty}^{\infty} f_{x|y}(x|y) \cdot f_y(y) dy$$

(B)



(LR) dk

$$f_x(x) = \int_{-\infty}^{\infty} f_{x,y}(x,y) \cdot dy$$

výjde nám z definice  
podm. hustoty,

pomocí ekvivalence

přejdeme k distribucím

fci a ukážeme, že

když integrujeme

očekávanou hustotu  $f_x(x)$

fci ukáčeme dostaneme distribuci fci  $F_x(x)$  a proto to platí

ekvivalentně:

$$F_x(x) = \iint_{-\infty}^{x} f_{x,y}(s,t) ds dt$$

\* tolle je vlastně  
integral přes mějakou  
množinu B

tady integrujeme

$$= \iint f_{x,y}(s,t) ds dt = P((x,y) \in B) = P(X \leq x) = F_x(x)$$



## Spojita Bayesova věta

Prozatím jsem sliboval,  
majdem věc statistice

v diskrétním jevíme vztěl:

$$P(A|B) \rightsquigarrow P(B|A)$$

myší dleme

$$f_{x|y} \rightsquigarrow f_{y|x}$$

## druhá definice kovariance

$$\text{cov}(x, y) = \mathbb{E}(xy) - \mathbb{E}(x) \cdot \mathbb{E}(y)$$

dk   $\approx$  definice kovariance a linearity  $\mathbb{E}$

$$\text{cov}(x, y) = \mathbb{E}((x - \mathbb{E}(x)) \cdot (y - \mathbb{E}(y)))$$

$$= \mathbb{E}(xy - x\mathbb{E}(y) - y\mathbb{E}(x) + \mathbb{E}(x)\mathbb{E}(y))$$

$$= \mathbb{E}(xy) - \mathbb{E}(x \underbrace{\mathbb{E}(y)}_{\text{komst}}) - \mathbb{E}(y \underbrace{\mathbb{E}(x)}_{\text{komst}}) + \mathbb{E}(\underbrace{\mathbb{E}(x)}_{\text{komst}} \cdot \underbrace{\mathbb{E}(y)}_{\text{komst}})$$

$$= \mathbb{E}(xy) - \mathbb{E}(y)\mathbb{E}(x) - \mathbb{E}(x)\mathbb{E}(y) + \mathbb{E}(x)\mathbb{E}(y) \cdot (1)$$

$$= \mathbb{E}(xy) - \mathbb{E}(x)\mathbb{E}(y)$$

 proc  
konstanta???

$$\mathbb{E}(ax) = a \cdot \mathbb{E}(x)$$

komstantu tedy  
vytknu před  
aplikaci "venkovní"  
střední hodnoty

## diskretny

- $\text{var}(x) = \text{cov}(x, x)$
- $\text{cov}(x, a \cdot y + bz + c) =$   
 $= a \cdot \text{cov}(x, y) + b \cdot \text{cov}(x, z)$
- $x, y$  nezávislé  $\Rightarrow$   
 $\text{cov}(x, y) = 0$

$$\mathbb{E}(xy) = \mathbb{E}(x) \cdot \mathbb{E}(y)$$

potom

$$\text{cov}(x, y) = \mathbb{E}(xy) - \mathbb{E}(x)\mathbb{E}(y) = 0$$

ulazíli jsme  
pro diskretní  
ale praktičně  
obecné



## Rozptyl súčtu

Nedľ  $X = \sum_{i=1}^n X_i$ , potom platí:

$$\text{var}(X) = \sum_{i=1}^n \sum_{j=1}^n \text{cov}(X_i, X_j) = \sum_{i=1}^n \text{var}(X_i) + \underbrace{\sum_{i \neq j} \text{cov}(X_i, X_j)}_{=0 \text{ pre } X_i, X_j \text{ nezávislé}}$$

Pro nezávislé m.v. speciálne platí:

$$\text{var}(X) = \sum_{i=1}^n \text{var}(X_i)$$

dk 

označme  $Y_i = (X_i - \mathbb{E}(X_i))$ ,  $Y = \sum_{i=1}^n Y_i = \sum_{i=1}^n X_i - \mathbb{E}(X_i)$

$$\text{var}(X) = \mathbb{E}(Y^2) = \mathbb{E}((X - \mathbb{E}(X))^2)$$

zároveň:

$$= \mathbb{E}(Y^2) = \mathbb{E}\left(\sum_{i=1}^n Y_i \cdot \sum_{j=1}^n Y_j\right) = \sum_{i=1}^n \sum_{j=1}^n Y_i \cdot Y_j = \sum_{i=1}^n \sum_{j=1}^n (X_i - \mathbb{E}(X_i)) \cdot (X_j - \mathbb{E}(X_j)) = \sum_{i=1}^n \sum_{j=1}^n \text{cov}(X_i, X_j)$$

To funguje protože tím, že

sumy násobíme, máme

$Y^2$

z definice  
kovariance

